

Biostatistica senza paura

quattro seminari introduttivi

Massimo Borelli



Corso di Laurea Magistrale in

BIOTecnologie
Innovative per la
SAlute



Copyright © 2026 Massimo Borelli, Ph.D.


FREELY AVAILABLE ON [HTTPS://GITHUB.COM/UMGSTAT/BIOTEC](https://github.com/UMGSTAT/BIOTEC)

Licensed under the Creative Commons Attribution-NonCommercial 4.0 License (the “License”). You may not use this file except in compliance with the License. You may obtain a copy of the License at <https://creativecommons.org/licenses/by-nc-sa/4.0>. Unless required by applicable law or agreed to in writing, software distributed under the License is distributed on an “AS IS” BASIS, WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied. See the License for the specific language governing permissions and limitations under the License.

First printing, May 2026



in memoriam
i professori Heather Bond e Gianni Morrone



Indice

1	Per iniziare	9
1.1	Biostatistica: una liturgia cosmetica?	9
1.2	Cosa faremo a lezione	11
1.3	... e se, un domani, volessimo approfondire?	12
1.3.1	Il linguaggio R	12
1.3.2	Le interfacce grafiche utente del linguaggio R	13
1.3.3	JASP	14
1.4	Convenzioni tipografiche di questa dispensa	14

I

Il foglio elettronico intelligente

2	Gli strumenti che useremo	19
2.1	Potenzialità e limiti di Google Fogli	19
2.2	Conosciamo l'editor di Apps Script	20
3	Presentare i dati correttamente	23
3.1	Descrizioni numeriche	23
3.1.1	Dati qualitativi e dati quantitativi	23
3.1.2	Attenzione: garantire la qualità del dato	25
3.1.3	Indici di centralità e di dispersione per i dati qualitativi	26
3.1.4	Indici di centralità e di dispersione per i dati quantitativi	29
3.2	Descrizioni grafiche	30
3.2.1	Un'immagine vale più di mille parole	30
3.2.2	Ricordiamoci sempre di rispettare i nostri interlocutori	31
3.3	Tutto chiaro?	31

II**Tenere sotto controllo il caso**

4	Il calcolo delle probabilità ci aiuta	35
4.1	Le variabili aleatorie discrete	35
4.2	Due pensieri a confronto: von Mises e de Finetti	37
4.3	Simulare numeri casuali	38
4.4	Altre variabili aleatorie	40
4.4.1	La distribuzione normale	40
4.4.2	La distribuzione lognormale	41
4.4.3	La distribuzione di Poisson	43
4.4.4	La distribuzione di Weibull	45
4.5	Un grafico con il nome buffo: il Q-Q plot	46
5	Presentare i dati: conclusione	49
5.1	Siamo pronti: la famigerata Tabella 1	49
5.1.1	Perché la Tabella 1 è famigerata?	50
6	Rischio e probabilità	53
6.1	Probabilità a priori ed a posteriori	53
6.2	Quantificare il rischio	57
6.2.1	Il teorema di Bayes	58

III**Dal particolare all'universale**

7	Oggi parliamo con Ilenia Aversa	63
7.0.1	Indici di dissimilarità	65
8	Generalizzare un esperimento	69
8.1	Dal campione alla popolazione	69
8.2	L'errore standard della media	71
8.3	Guai a confondere la variabilità con l'affidabilità	74
9	Che cos'è un test statistico	77
9.1	il signor Student ed il suo T-Test	77
9.1.1	Come eseguire il t test con il foglio elettronico	81
9.1.2	Come eseguire il t test con R	81
9.1.3	Prendere una decisione finale	84
9.2	La signora che gustava il tè, ed i guai che ne seguirono	84

IV**Progettare ciò che vogliamo scoprire**

10	Dialogando con Flavia Biamonte e Martina Battaglia	89
10.1	Progettare correttamente un esperimento	89

11	Conclusioni e ringraziamenti	93
	Bibliografia	95
	Articoli	95
	Libri	95
	Indice analitico	96



1. Per iniziare

1.1 Biostatistica: una liturgia cosmetica?

Questo libro raccoglie gli appunti e le schede delle lezioni di un breve corso di Biostatistica tenuto durante il secondo semestre del 2026 presso la Scuola di Farmacia e Nutraceutica dell'Università Magna Græcia di Catanzaro. Questo libro si può scaricare gratuitamente dall'indirizzo <https://github.com/umgstat/biotec>.

Il ciclo di seminari nasce, nella mente della professoressa Donatella Malanga, un anno fa, nel giardino di casa mia a Trieste, con l'obiettivo di rivolgerci splicitamente alle studentesse ed agli studenti del quinto anno del corso di laurea magistrale in Biotecnologie, per introdurre i concetti fondamentali della biostatistica attraverso un approccio esplicitamente orientato al *ragionamento sui dati*, più che all'uso di specifici software statistici. Infatti, nelle scienze della vita, la statistica rappresenta uno strumento indispensabile per descrivere, interpretare e discutere dati sperimentali; tuttavia, la sua comprensione è spesso ostacolata da “barriere tecnologiche” (i software specifici per l'analisi dei dati), oppure da formalismi e concetti matematici percepiti come eccessivi, se non arcani; oppure, dall'uso di tecniche che, pur consolidate e potenti, tendono a nascondere i meccanismi concettuali sottostanti alle analisi. Il risultato è che le studentesse e gli studenti vengono indotti a pensare che la biostatistica altro non sia che una **liturgia**: un rituale, una cerimonia di formule e di frasi da scrivere per uno finalità esclusivamente **cosmetica**: “abbellire” la tesi, “impreziosire” la ricerca, far apparire “professionale” il report.

Abbiamo perciò pensato esplicitamente ai laureandi magistrali in quanto persone che possiedono già una solida formazione disciplinare nelle scienze della vita, ma che non necessariamente sono orientate verso un futuro percorso di ricerca biomedica. Tuttavia, alla maggior parte di essi, nella loro carriera lavorativa futura verrà richiesto di

- avere familiarità con dati sperimentali e numerici;
- raffrontarsi più o meno frequentemente con i risultati statistici riportati nella letteratura scientifica, pur partendo da ricordi e onoscenze statistiche frammentarie;
- sopperire ad una, nella maggior parte dei casi, limitata esperienza di programmazione

Non da ultimo, a breve essi saranno chiamati a redigere la loro tesi magistrale e pertanto, urge qui fornire alcuni strumenti concettuali di base per comprendere, valutare e presentare dati quantitativi in modo consapevole: in breve, stiamo parlando di quella che viene definita come *alfabetizzazione statistica* (*statistical literacy*), intesa come la capacità di:

- comprendere come i dati vengono descritti e sintetizzati;

- formulare correttamente una domanda statistica a partire da un problema scientifico;
- riconoscere le assunzioni dei principali test statistici univariati;
- interpretare correttamente misure di variabilità, intervalli di fiducia ('confidenza') e p-value;
- valutare criticamente analisi statistiche prodotte da altri.

Ecco perché cercheremo di porre l'enfasi sul *significato* dei risultati statistici (e sui loro limiti), piuttosto che sull'esecuzione meccanica delle analisi per tramite di un software: non ci interessa sapere "quale pulsante schiacciare", ma piuttosto capire cosa ci sia "dietro" a quel pulsante, quale sia l'idea di fondo. Sono passati vent'anni ormai da quando, su JAMA [10], si lanciava l'allarme sul fatto che i medici specializzandi statunitensi rischiassero di concludere il loro percorso formativo e divenire specialisti senza avere acquisito gli strumenti statistici necessari per interpretare i risultati pubblicati nelle ricerche cliniche (ed, ironicamente, tale conclusione veniva suffragata da pagine e pagine di confidence interval, p – value, odds ratio e curve di Kaplan Meier: forse per incutere timore agli specializzandi, appunto).

ORIGINAL CONTRIBUTION

Medicine Residents' Understanding of the Biostatistics and Results in the Medical Literature

Dorina M. Windich, MD, MPH
Stephen J. Haist, MD, PhD
Michael L. Gross, MD, MSc

PHYSICIANS MUST KEEP CURRENT with clinical information to practice evidence-based medicine (EBM). In doing so, most prefer to seek evidence-based summaries, which give the clinical bottom line,¹ or evidence-based practice guidelines.^{2,3} However, that maintain these information summaries, however, currently include a limited number of common conditions.⁴ Thus, to answer many of their clinical questions, physicians need to access reports of original research. This requires the reader to critically appraise the design, conduct, and analysis of each study and subsequently interpret the results.

Several surveys in the 1980s demonstrated that practicing physicians, particularly those with no formal education in epidemiology and biostatistics, had a poor understanding of common statistical tests and limited ability to interpret study results.⁵⁻⁷ Many physicians likely have increased difficulty today because more complicated statistical methods are being reported in the medical literature.⁸ They may be able to understand the analysis and interpretation of results in only 21% of research articles.⁹

Educators have responded by increasing training in critical appraisal and biostatistics throughout the continuum of medical education. Many medical

Context. Physicians depend on the medical literature to keep current with clinical information. Little is known about residents' ability to understand statistical methods or how to appropriately interpret research outcomes.

Objective. To evaluate residents' understanding of biostatistics and interpretation of research results.

Design, Setting, and Participants. Multiprogram cross-sectional survey of internal medicine residents.

Main Outcome Measure. Percentage of questions correct on a biostatistics/study design multiple-choice knowledge test.

Results. The survey was completed by 277 of 367 residents (75.5%) in 11 residency programs. The overall mean percentage correct on statistical knowledge and interpretation of results was 41.4% (95% confidence interval [CI], 39.7%–43.3%) vs 71.5% (95% CI, 57.5%–85.5%) for fellow and general medicine faculty with research training ($P < .001$). Higher scores in residents were associated with additional advanced degrees (50.0% [95% CI, 44.5%–55.5%] vs 40.1% [95% CI, 38.3%–42.0%], $P < .001$), prior biostatistics training (48.2% [95% CI, 42.7%–53.7%] vs 37.9% [95% CI, 35.4%–40.3%], $P = .001$), enrollment in a university-based training program (43.0% [95% CI, 41.0%–45.1%] vs 36.3% [95% CI, 32.6%–40.0%], $P = .002$), and male sex (44.0% [95% CI, 41.4%–46.7%] vs 38.8% [95% CI, 36.4%–41.1%], $P = .004$). On individual knowledge questions, 81.6% correctly interpreted a relative risk. Residents were less likely to know how to interpret an adjusted odds ratio from a multivariate regression analysis (37.4%) or the results of a Kaplan-Meier analysis (10.5%). Seventy-five percent indicated they did not understand all of the statistics they encountered in journal articles, but 95% felt it was important to understand these concepts to be an intelligent reader of the literature.

Conclusions. Most residents in this study lacked the knowledge in biostatistics needed to interpret many of the results in published clinical research. Residency programs should include more effective biostatistics training in their curricula to successfully prepare residents for this important lifelong learning skill.

JAMA. 2007;298:1019–1022

www.jama.com

schools currently provide some formal teaching of basic statistical concepts.⁸ As part of the Accreditation Council for Graduate Medical Education's practice-based learning and improvement competency, residents must demonstrate ability in "locating, appraising, and assimilating evidence from scientific stud-

ies related to their patients' problems and apply knowledge of study designs and statistical methods to the appraisal of

Author Affiliations: Department of Internal Medicine, Yale University School of Medicine, New Haven, Conn (Windich);

Corresponding Author: Dorina M. Windich, MD, MPH, Yale Primary Care Residency Program, 400 Oakdale St, Westbury, CT 06788 (dorina.windich@yale.edu).

RESIDENTS' UNDERSTANDING OF PUBLISHED BIostatISTICS AND RESULTS

Table 4. Knowledge Scores by Resident Characteristics*

Characteristic	Bivariate Analyses		Multiple Linear Regression	
	Mean Correct, % (95% CI)	P Value	Score Difference, % ^b (95% CI)	P Value
Sex				
Woman	39.8 (36.4 to 43.1)	.004 ^c	—1.1 (Intercept)	.01
Man	43.0 (41.4 to 44.6)		4.3 (3.7 to 4.9)	
Age, yr				
21–25	44.4 (39.8 to 49.0)	.49 ^d		
26–30	41.7 (38.3 to 45.0)			
31–35	41.0 (37.5 to 44.5)			
≥36	37.3 (30.4 to 44.2)			
Other advanced degrees				
No	40.1 (38.3 to 41.9)	<.001 ^e	—1.1 (Intercept)	<.001
Yes	50.0 (46.5 to 53.5)		9.2 (8.2 to 10.2)	
Years since medical school graduation				
≤1	43.2 (40.4 to 46.0)	<.001 ^e	—1.1 (Intercept)	.08
2–3	43.2 (38.8 to 47.6)		—3.3 (–5.0 to –1.6)	
4–10	39.8 (35.8 to 43.8)		–4.7 (–6.4 to –3.0)	
≥11	34.5 (27.9 to 41.1)		–12.3 (–15.2 to –9.3)	
Training outside of the United States				
No	40.2 (37.7 to 42.7)	<.001 ^e		
Yes	37.9 (35.4 to 40.3)			
Academic affiliation of program				
Community-based	39.3 (37.8 to 40.8)	.002 ^e	—1.1 (Intercept)	.02
University-based	43.0 (41.2 to 44.8)		3.6 (3.0 to 4.2)	
Current level of training				
Entering intern	43.6 (40.8 to 46.4)	.01 ^e		
Experienced intern	39.2 (36.7 to 41.7)			
Second-year resident	39.3 (34.9 to 43.7)			
Third-year resident	39.4 (33.5 to 45.3)			
Fourth-year resident	43.3 (35.3 to 51.3)			
Chief resident	39.1 (31.3 to 46.9)			
Current residency training program type				
Traditional/categorical medicine	39.8 (37.5 to 42.1)	.002 ^e		
Primary care medicine	42.4 (39.3 to 45.5)			
Medicine/pediatrics	54.6 (51.2 to 58.0)			
Medicine/preventive medicine	53.6 (47.8 to 59.4)			
Prebiopsy/therapeutic care	41.0 (39.8 to 42.1)			
Previous training coursework in biostatistics				
No	37.0 (35.4 to 38.6)	.001 ^e	—1.1 (Intercept)	.04
Yes	45.2 (42.7 to 47.7)		4.3 (3.7 to 4.9)	
Location of biostatistics training				
College	38.1 (31.7 to 44.5)	.004 ^e		
Medical school	42.2 (40.2 to 44.2)			
Residency	39.8 (36.2 to 43.4)			
Other	51.0 (44.8 to 57.2)			
Previous training coursework in epidemiology				
No	37.0 (34.8 to 39.2)	.003 ^e		
Yes	43.3 (41.1 to 45.5)			
Previous training coursework in evidence-based medicine				
No	39.0 (35.8 to 42.1)	.04 ^e		
Yes	42.9 (40.7 to 45.0)			
Residency reads medical journals				
No	42.2 (39.3 to 45.1)	.03 ^e		
Yes	47.0 (44.8 to 49.2)			

*For multivariate regression analyses, $P < .05$ is considered statistically significant.

^bUsing forward stepwise regression. ^cInteracts with advanced degree status, since medical school graduation, program affiliation, and biostatistics training were found to be associated with knowledge scores. The P value for the final model was .15.

^dAdjusted for sex.

^eAdjusted for year.

^fThe multivariate regression model was not normally distributed. Median (interquartile range, 40% (25%–75%)).

^gEvidence-based medicine is defined as the rigorous critical appraisal of research evidence with patients' values and clinical circumstances in clinical decision making. This is in contrast to biostatistics, which is the scientific use of quantitative information to describe or draw inferences about natural phenomena, and epidemiology, which is the study of patterns, causes, and control of disease in groups of people.

1.2 Cosa faremo a lezione

Proprio per queste motivazioni, abbiamo scelto di orientare il nostro discorso alle biotecnologie e deliberatamente di “abbassare la soglia tecnologica iniziale”: invece di ricorrere a software statistici (SPSS, SAS, Stata, ...) o linguaggi di programmazione (Python, R, ...) dedicati, il nostro percorso didattico si basa su:


- il foglio elettronico (Google Sheets);
- semplici meccanismi di automazione (Apps Script);
- il supporto dell’intelligenza artificiale per la scrittura e la comprensione del codice (JavaScript).

il foglio elettronico

La cosa che mi preme maggiormente in questo corso è quella di “mettersi comodi”, come quando torni a casa e ti metti le pantofole, o i pantaloni della tuta e ti stravacchi sul divano. E lo strumento più comodo per iniziare a fare statistica è, secondo me, il foglio elettronico.


Voglio però mettere le mani avanti: questa scelta non implica affatto che il foglio elettronico si debba considerare come lo strumento ideale per la statistica avanzata (... anzi ...); la scelta risponde solamente all’esigenza di mettere in atto una **didattica laboratoriale**, quella cioè di fare esperienza con i dati numerici in un ambiente familiare, che renda i dati e le trasformazioni su di essi trasparenti e direttamente osservabili, mantenendo invariato il livello concettuale richiesto a livello di laurea magistrale italiana. Pertanto, Google Sheets verrà utilizzato come ambiente di lavoro principale perché consente di:

- essere collaborativi e condividere istantaneamente le esercitazioni
- ridurre l’attrito tecnologico iniziale;
- concentrarsi sui dati e sui concetti statistici, non sulle parentesi e le interpunzioni;
- rendere visibili le operazioni di manipolazione e di analisi.



l’automazione tramite Apps Script

Se Google Sheets è il nostro divano incredibilmente comodo per gestire i dati rilassandoci, imparare ad usare **Apps Script** significa trasformare quel divano in una postazione domotica super tecnologica, dove tutto ci viene portato direttamente sotto il naso senza muovere un dito.



Se non sappiamo già usare le formule base, o se abbiamo imparato ad usarle ma ci tocca perdere tempo in compiti ripetitivi e noiosi, come copiare dati di ogni esperimento, abbellirli con le tabelle formattate come vuole qualcun altro, usando Apps Script si può automatizzare tutto questo in pochi secondi: scrivendo poche righe di codice in JavaScript — un linguaggio utilissimo anche al di fuori dei fogli di calcolo — si riesce ad automatizzare Google Sheets, facendolo anche dialogare

direttamente con Gmail, con Google Drive o con Calendar. Ovviamente, queste “macro” di Apps Script bisogna essere capaci di sapersele scrivere, ed ecco perché le introdurremo, in forma guidata, in pochi e semplici esempi, con lo scopo di:

- automatizzare procedure ripetitive;
- mostrare il carattere algoritmico di un’analisi statistica;
- introdurre gradualmente ai meno esperti il concetto di codice come descrizione formale di una procedura.

l'intelligenza artificiale

L'intelligenza artificiale verrà utilizzata come strumento di supporto alla scrittura e alla comprensione del codice, non come sostituto del ragionamento statistico. Le decisioni metodologiche, le ipotesi e l'interpretazione dei risultati resteranno sempre in carico agli studenti (ed a noi mentori).

Cosa hai in mente?

.. mah, io niente; vorrei invece capire cosa ha in mente questo Prof, che sta parlandomi di Google Sheets e di Apps Script, di cui non so una beata mazza ..

+



1.3 ... e se, un domani, volessimo approfondire?

Se un domani vorrete diventare ricercatrici e ricercatori esperti e dovrete eseguire calcoli bioinformatici e biostatistici “pesanti”, diventerà necessario utilizzare un linguaggio di programmazione come Python o Java <https://bit.ly/41G0AaQ>. Ma se invece dovrete svolgere analisi “di routine”, qualsiasi pacchetto statistico commerciale come SPSS, Stata o SAS <https://bit.ly/3tuJT1X> rappresenterà una soluzione ottimale. Tuttavia, la comunità accademica è particolarmente affezionata a R, e alle sue versioni più semplici come le cosiddette “suite statistiche” quali R Commander, Jamovi o JASP. Spendiamo ora poche parole per introdurre quest'ultime.

1.3.1 Il linguaggio R

R è un ambiente software open source per il calcolo statistico e la grafica, che può essere scaricato gratuitamente dai cosiddetti mirror CRAN (Comprehensive R Archive Network) distribuiti in tutto il mondo: <https://cran.r-project.org/mirrors.html>. R funziona su piattaforme UNIX/Linux, Windows e MacOS. È inoltre possibile sfruttare le risorse di cloud computing e compilare online i propri script su <https://rdrr.io/snippets/>.

web

Se siete interessate/i ad alcuni dettagli storici, Nick Thieme ha pubblicato un articolo^[7] che ripercorre lo straordinario successo di R, nato più o meno venticinque anni fa all'Università di Auckland dalle idee di due professori di statistica: Ross Ihaka e Robert Gentleman. Ulteriori dettagli sono forniti da Carlos Alberto Gómez Grajales nel suo articolo *Created by statisticians for statisticians: How R took the world of statistics by storm*, apparso su <http://www.statisticviews.com/view/index.html>.

Naturalmente, R è molto ben documentato; ad esempio, si possono trovare online libri introduttivi gratuiti, come il testo di Hadley Wickham e Garrett Golemund ^[19] *R for data science*, disponibile all'indirizzo <https://r4ds.had.co.nz/>, oppure il testo di Kim Seefeld ed Ernst Linder *Statistics Using R with Biological Examples*, disponibile su https://cran.r-project.org/doc/contrib/Seefeld_StatsRBio.pdf. Esistono inoltre numerose pagine web, blog e MOOC dedicati a R; ad esempio:

- http://ncss-tech.github.io/stats_for_soil_survey/chapters/
- <http://www.sthda.com/english/wiki/r-software>
- Quick-R, <https://www.statmethods.net/>

Sono disponibili anche molti video tutorial su YouTube, cercando https://www.youtube.com/results?search_query=R+tutorial.

Invece di lavorare direttamente nella console di R, molti studiosi preferiscono utilizzare l'Integrated Development Environment (IDE) R Studio <https://www.rstudio.com/>. R Studio è apprezzato perché garantisce un ambiente di programmazione e di grafica stabile e ben integrato. Un grave

svantaggio di R è sempre stata la sua “ripida curva di apprendimento”: il principiante doveva dedicare molto tempo a fare pratica nella gestione di sintassi e comandi, oltre allo sforzo richiesto per apprendere la Statistica. In questi tempi di intelligenza artificiale gratuita le cose sono diventate molto, ma mooolto più semplici.

```

1 10 + 20 * 30
2 1/0
3 print('Welcome to ICTP')

```


```

> 10 + 20 * 30
[1] 610
> 1/0
[1] Inf
> print('Welcome to ICTP')
[1] "Welcome to ICTP"
>

```

Essendo R un linguaggio di programmazione, è ovviamente possibile iniziare copiando e incollando porzioni di codice trovate in rete, semplicemente “googlando” o “chatgipittando” ciò di cui si ha bisogno. Tuttavia, per padroneggiare il linguaggio è necessario dedicare molto tempo alla pratica: i neofiti trovano frustrante cercare il simbolo $\sim$ sulla tastiera, oppure si bloccano quando copiano del codice da un PDF in cui è scritto $x - y$ (con l’“en dash” a quattro punti), mentre il software deve leggere $x - y$ (con il segno meno, cioè l’“hyphen” a tre punti).

1.3.2 Le interfacce grafiche utente del linguaggio R



I principianti trovano spesso sufficiente accedere a una selezione dei comandi R più comunemente utilizzati tramite interfacce grafiche utente “familiari”, come R Commander, <https://www.rcommander.com/>, oppure Jamovi, <https://www.jamovi.org/>. In R Commander è presente un ambiente a menu con una sezione di input, chiamata R Script, creata tramite la procedura File | New Script; e una sezione Output che elenca i comandi inseriti e produce i risultati. In basso, la sezione a sfondo grigio fornisce i Messages, che segnalano eventuali incongruenze. In Jamovi, le capacità di foglio di calcolo per la gestione dei dati grezzi sono integrate con un menu di comandi di analisi tipici di R. Il manuale utente <https://www.jamovi.org/user-manual.html> aiuta il principiante ad apprendere le procedure di base.

1.3.3 JASP



Una decina di anni fa, un gruppo di persone appartenenti agli ambiti della ricerca sociale (principalmente dell'Università di Amsterdam, <https://cordis.europa.eu/project/id/283876>) iniziò a lavorare a una sorta di “SPSS libero e open source”, essendo quest’ultimo una specie di *lingua franca* parlata dagli psicometristi. L’idea era brillante: utilizzare R come motore nascosto (in particolare, sfruttando il pacchetto BayesFactor) e racchiuderlo in un’interfaccia “drag and drop”; il risultato fu la creazione di JASP, che può essere scaricato gratuitamente da <https://jasp-stats.org/team/>. L’obiettivo originario era promuovere l’approccio bayesiano al test delle ipotesi nelle scienze sociali, riconoscendo che i principali progressi della statistica computazionale avrebbero dovuto avere un impatto positivo sulle metodologie psicometriche tradizionali (o, come sostenevano, addirittura inappropriate). JASP è anch’esso molto ben documentato, e i neofiti possono iniziare consultando <https://jasp-stats.org/getting-started/> oppure <https://jasp-stats.org/how-to-use-jasp/>; sono inoltre molto validi i manuali gratuiti disponibili su <https://jasp-stats.org/jasp-materials/>. Non a caso, anche la nostra università è amica di JASP (<https://jasp-stats.org/world-map/>), e tanti dottorandi amano seguire il nostro corso introduttivo, <https://sites.google.com/unicz.it/massimoborelli/home>.

1.4 Convenzioni tipografiche di questa dispensa

Come vedrete, in questo libro abbiamo adottati alcune convenzioni tipografiche; ad esempio, troverete inviti a consultare qualche risorsa online che - a mio giudizio, ovviamente - sembra essere particolarmente ben scritta, o di una certa importanza. La troverete evidenziata da un circoletto azzurro, con la scritta **web**:



Jonathan Ball, Viv Bewick and Liz Cheek. Medical statistics.
<https://www.biomedcentral.com/collections/cc-medical>

Durante il corso eviteremo, come se fossimo i diavoli che cercano di nuotare in una piscina di acqua benedetta, le slides, proprio perché rimaniamo convinti che se prendiamo qualche appunto con carta e matita (approfittando del gadget offerto dal Corso) e se “facciamo con le nostre mani” il lavoro, fissiamo meglio i concetti nella nostra memoria. Ecco perché ci avvarremo di schede di lavoro, come in questo esempio:

Attività didattica 1.1 — Scheda. Consultate, di volta in volta, le istruzioni contenute in una scheda, che potete liberamente scaricare da:

<https://github.com/umgstat/biotec/tree/main/schede> ■

Al nostro fianco, ci sarà sempre pronta a dare una mano l'intelligenza artificiale, per fare in modo che non ci si debba “incastrare” sui piccoli dettagli tipografici che talvolta, anzi spesso, insidiano le studentesse e gli studenti alle prime esperienze con le sintassi dei comandi, delle funzioni, dei codici di programmazione. Useremo Gemini perché ci viene offerta gratuitamente dall'ateneo:



Utente

Buongiorno Gemini. Sei pronta a darmi una mano ad imparare ad usare in maniera avanzata il foglio elettronico Google Sheet?

I codici di programmazione che via via impareremo ad utilizzare saranno trascritti in un box grigio con il bordo azzurro. Ecco un esempio, il cui significato ci apparirà chiarissimo fra poche pagine:

codice 1.1 — il primo tentativo. Risale al 1974, e precisamente ad un *gray paper* di Brian Kernighan, pubblicato dall'azienda Bell Laboratories ed intitolato *Programming in C: A Tutorial* il più classico degli output di un programma:

```
/**
 * Scrive "Hello, World!" nella cella A1 del foglio attivo
 */
function salutaMondo() {
  const foglio = SpreadsheetApp.getActiveSpreadsheet().getActiveSheet();
  foglio.getRange("A1").setValue("Hello, World!");
}
```

Di quando in quando, proporremo anche qualche definizione importante, nell'intento di arricchire il nostro personale:

■ **Vocabolario 1.1 — parola da ricordare.** In questo modo metteremo l'accento sulla terminologia *must-know* che frequentemente viene usata nel mondo della biostatistica.

oppure, chiederemo di provare a pensare da soli a trovare la soluzione di qualche quesito, ragionando in analogia ai discorsi che avremo appena trattato

■ **Attività 1.1 — mettili alla prova.** Prova a fare qualche cosa, magari facendo suggerire qualche idea dagli amici del tuo gruppo o eventualmente dall'intelligenza artificiale. ■

Infine, vedremo anche di consigliarvi a varcare la soglia della biblioteca, con qualche cosa del tipo:

Approfondimento 1.1 — andate a leggere i libri. Perché c'è sempre tanto da imparare, ed il nostro Ateneo ve li presta gratuitamente.

Il foglio elettronico intelligente

2	Gli strumenti che useremo	19
2.1	Potenzialità e limiti di Google Fogli	19
2.2	Conosciamo l'editor di Apps Script	20
3	Presentare i dati correttamente	23
3.1	Descrizioni numeriche	23
3.2	Descrizioni grafiche	30
3.3	Tutto chiaro?	31



2. Gli strumenti che useremo

Il nostro percorso didattico adotta Google Fogli come una **palestra concettuale**: un ambiente trasparente e collaborativo che ci permetta di mantenere il focus sul dato biologico, riducendo le barriere tecnologiche iniziali. Sebbene lo strumento presenti limiti intrinseci in termini di scalabilità e riproducibilità rispetto a software specialistici, tali criticità vengono mitigate dall'integrazione di **Apps Script**. L'accesso all'Editor di script trasforma il foglio elettronico in un ambiente di sviluppo (IDE) completo, dove la logica algoritmica e il supporto dell'intelligenza artificiale si fondono per aiutare gli studenti ad automatizzare le analisi, rendendoli capaci provare a “governare” il flusso dei dati oltre le funzioni predefinite.

2.1 Potenzialità e limiti di Google Fogli

La scelta di adottare Google Sheets (o Google Fogli) come strumento didattico non è dettata da una preferenza tecnologica assoluta, ma da un bilancio costi-benefici mirato all'apprendimento. È fondamentale avere una consapevolezza di cosa si possa fare con questo strumento e, soprattutto, di quando sia necessario migrare verso soluzioni più robuste.

Punti di forza e potenzialità

Il foglio elettronico, così come inserito nell'*ecosistema cloud* del nostro Ateneo, offre parecchi vantaggi per la didattica laboratoriale:

- **Interfaccia “Trasparente”:** A differenza dei software *point-and-click* (come SPSS, GraphPad Prism, ..) o dei linguaggi di programmazione (come Python, R, ...), Google Sheets mostra il dato e la sua trasformazione nello stesso spazio visivo. Questa vicinanza fisica tra input e output aiuta a comprendere le azioni e le operazioni statistiche.
- **Collaborazione in tempo reale:** La biotecnologia per sua intrinseca natura è una scienza collaborativa. La possibilità per più studenti di lavorare simultaneamente sullo stesso dataset, commentando le analisi e condividendo i risultati, riflette le dinamiche dei laboratori di ricerca anche di natura aziendale.
- **Estensibilità tramite Apps Script:** La presenza, come vedremo meglio fra poco, di un motore JavaScript integrato permette di superare i limiti delle funzioni predefinite, consentendo di creare funzioni personalizzate e di automatizzare il flusso di lavoro (workflow) senza dover installare ambienti di sviluppo complessi.
- **Accessibilità e Cloud:** Non vi sono barriere legate all'hardware o al sistema operativo. Il calcolo avviene sui server, garantendo che ciascuno lavori nelle stesse identiche condizioni tecniche.


Limiti intrinseci e “soglie di rischio”

Nonostante le potenzialità, il foglio elettronico presenta dei limiti strutturali che lo rendono inadatto per certi ambiti della ricerca avanzata:

- **Integrità dei dati e Audit Trail:** Google Sheets permette la modifica diretta delle celle: questo espone al rischio di errori accidentali (es. sovrascrittura di una formula) che sono difficili da tracciare rispetto a uno script R o Python, dove il dato originale rimane solitamente immutato (*read-only*).
- **Scalabilità (Big Data):** le biotecnologie moderne (-omiche, sequenziamenti, ...) possono generare istantaneamente milioni di righe di dati. Google Sheets ha limiti fisici sul numero di celle gestibili, oltre i quali le prestazioni degradano fino all'instabilità.
- **Riproducibilità limitata:** la manipolazione manuale dei dati e delle analisi (copia-incolla, ordinamento manuale) rimane la causa principale di errori non riproducibili nella letteratura scientifica prodotta tramite fogli elettronici.
- **Assenza di test statistici avanzati:** molti modelli complessi (modelli lineari generalizzati, modelli misti, analisi di sopravvivenza avanzate, ...) non sono disponibili come funzioni native e richiederebbero un'implementazione manuale eccessivamente onerosa in Sheets.

In sintesi, ecco perché in questi quattro seminari utilizzeremo Google Sheets come una **palestra concettuale**. Impareremo a “vedere” la statistica tra le celle, sapendo che le competenze logiche acquisite saranno poi facilmente trasferibili, in futuro, a linguaggi di programmazione più complessi e potenti.

2.2 Conosciamo l'editor di Apps Script



Quando cliccheremo per la prima volta su Apps Script all'interno del menu Estensioni di Google Fogli, il browser aprirà una nuova scheda separata dal foglio di calcolo. Quello che appare non è più una griglia di celle, ma un vero e proprio IDE (Integrated Development Environment) basato su cloud. L'interfaccia è divisa in tre sezioni verticali, pensate per guidare l'utente dalla gestione dei file fino alla scrittura del codice; vi sono poi due sezioni di salvataggio e condivisione.

1. La barra laterale sinistra: il centro di controllo

Sul bordo sinistro si trova una stretta colonna di icone scure. Questa barra permette di navigare tra le diverse "viste" del progetto:

- **Editor (*Icona del codice*):** è la vista predefinita dove si scrive fisicamente lo script.
- **Attivatori (*Icona della sveglia*):** Una sezione fondamentale dove si può istruire Google a eseguire un codice al verificarsi di un evento, ad esempio ogni lunedì mattina o ogni volta che qualcuno modifica una cella.
- **Esecuzioni (*Icona dell'elenco*):** Qui la studentessa potrà controllare lo storico di tutti i lanci dello script, verificando se sono andati a buon fine o se si sono interrotti con un errore.
- **Impostazioni del progetto (*Icona dell'ingranaggio*):** Per configurare parametri avanzati o collegare lo script a una Google Cloud Platform.

2. Il pannello dei file: l'archivio del progetto

Immediatamente a destra della barra scura, compare un pannello bianco chiamato File: di default, Google crea un file denominato `Codice.gs` e l'estensione `.gs` sta per "Google Script". Qui la studentessa può cliccare sul simbolo "+" per aggiungere nuovi file di script o file HTML (utili se desidera creare finestre pop-up personalizzate all'interno di Fogli).

3. l'editor di testo: il cuore della scrittura del codice

La parte più ampia dello schermo è occupata dall'editor di testo. Al primo accesso, Google inserisce automaticamente uno scheletro di funzione vuota:

```
function myFunction() {  
  
}
```

È qui che avviene la magia. L'editor non è un semplice blocco note: supporta l'autocompletamento (IntelliSense). Se la studentessa scrive "SpreadsheetApp.", l'editor mostrerà un elenco a discesa con tutti i comandi disponibili, spiegando a cosa servono. Se poi, come nel nostro caso, i codici ce li faremo scrivere dall'intelligenza artificiale, la magia sarà perfetta.

4. La barra degli strumenti

: importantissima Sopra l'area del codice si trova una barra orizzontale con alcuni tasti essenziali:

- **Menu delle funzioni:** un piccolo menu a tendina che permette di scegliere quale specifica funzione eseguire (nel caso nel file ce ne siano più di una).
- **Esegui:** il tasto "Play" che avvia il codice.
- **Debug:** rappresentato da un'icona a forma di insetto, serve per analizzare il codice riga per riga alla ricerca di errori logici.
- **Log di esecuzione:** quando lo script viene avviato, nella parte inferiore dell'editor appare un pannello a comparsa che mostra i messaggi di sistema e gli eventuali errori in tempo reale.

5. Il deployment del progetto: non ci riguarda

Con il termine *deployment* in informatica intendiamo l'operazione con cui uno script viene pubblicato come applicazione a se stante, come **Web App** per essere utilizzata da utenti diversi dalla studentessa che ha scritto il codice. Quindi, tramite il pulsante **Esegui il deployment** è possibile definire anche chi possa accedere allo script e quale versione del codice viene resa attiva. Nel nostro corso, gli script verranno utilizzati solo per automatizzare alcune procedure nel foglio di calcolo e non avremo bisogno di alcun deployment.



3. Presentare i dati correttamente

In questo Capitolo impareremo come riassumere dati numerici e non numerici e come presentarli ai lettori, sia in forma tabellare sia in forma grafica. Discuteremo inoltre il modo corretto di farlo, presentando alcuni errori tipici presenti in letteratura.

3.1 Descrizioni numeriche



Elise Whitley, Jonathan Ball. Statistics review 1: Presenting and summarising data
<https://ccforum.biomedcentral.com/articles/10.1186/cc1455>

Il primo obiettivo da raggiungere in qualsiasi analisi dei dati è “comprenderli”, descriverli e riassumerli in modo appropriato (senza essere né troppo prolissi, né troppo criptici). Un’analisi di questo tipo può mettere in luce valori “strani” (outlier), molto elevati o molto bassi rispetto al resto dei dati. Tabelle e grafici sono il modo usuale per riassumere grandi quantità di informazione e la review sopra citata richiama i concetti fondamentali, fornendo esempi di dati qualitativi (non ordinati e ordinati) e quantitativi (discreti e continui). Nella loro review, Elise Whitley e Jonathan Ball ricordano in che modo i diversi tipi di dati possano essere rappresentati, mettendo in evidenza due caratteristiche fondamentali di un dataset quantitativo: la **posizione** dei dati e la loro **variabilità**. Vengono così riviste le comuni misure di posizione (media, mediana e moda) e di variabilità (range, intervallo interquartile, deviazione standard e varianza).

3.1.1 Dati qualitativi e dati quantitativi

Attività didattica 3.1 — Scheda. Dati qualitativi e dati quantitativi:


<https://github.com/umgstat/biotec/blob/main/schede/scheda01.pdf> ■

Questa prima scheda ha l’obiettivo di individuare dei criteri operativi per stabilire la “natura” dei dati statistici e, conseguentemente, di indirizzare l’analisi descrittiva di un dataset. Si tratta di compilare un foglio elettronico Google Sheets, indicando

1. il tuo nome;
2. il tuo cognome;
3. la provincia in cui sei residente (sigla provinciale);
4. quanti chilometri dista, secondo Google Maps, la tua casa di residenza dalla sede di Germaneto nella quale ti trovi ora;

5. quanto sei d'accordo con la seguente affermazione: *Mi ritengo un'utente esperta/o del foglio elettronico.*? Per niente / poco / abbastanza / molto / del tutto.

In statistica, infatti, è fondamentale distinguere tra i diversi tipi di dati, poiché la natura delle variabili osservate condiziona profondamente il tipo di analisi che può essere eseguita e il modo corretto di interpretarne i risultati. Seguendo una classificazione classica, utilizzata ad esempio da Bernie Rosner [18] o da Martin Bland [13], i dati possono essere suddivisi in *qualitativi* e *quantitativi*.



Dati qualitativi. I dati qualitativi (o categoriali) descrivono una qualità, una caratteristica o una categoria alla quale un'osservazione appartiene. Non sono numerici in senso stretto e non ammettono operazioni aritmetiche significative.

- *Dati nominali:* le categorie sono prive di un ordine naturale. Esempi tipici sono il sesso biologico, il gruppo sanguigno, la presenza o assenza di una patologia, oppure la città di residenza.

Dati quantitativi. I dati quantitativi possono descrivere sia grandezze non numeriche, sia grandezze numeriche. Possono esservi dati che non sono numerici in senso stretto e non ammettono operazioni aritmetiche, ma possiedono un loro ordine naturale.

- *Dati ordinali:* le categorie possono essere ordinate secondo un criterio naturale, ma le distanze tra le categorie non sono definite o non sono confrontabili. Esempi comuni sono le scale di giudizio (scarso, sufficiente, buono, ottimo), i livelli di gravità di una malattia o le scale Likert.

Viceversa, abbiamo maggiore versatilità con i dati numerici per i quali le operazioni aritmetiche hanno senso. Essi possono quindi essere rappresentati su una scala numerica e consentono confronti in termini di differenze e, in alcuni casi, di rapporti.

- *Dati discreti, count:* assumono valori numerici interi separati, tipicamente ottenuti tramite conteggio. Esempi sono il numero di figli, il numero di eventi avversi o il numero di accessi ospedalieri.
- *Dati continui:* possono assumere qualunque valore reale all'interno di un intervallo. Altezza, peso, pressione arteriosa e concentrazione di una sostanza nel sangue sono esempi classici. Dal punto di vista della scala di misura, i dati quantitativi sono generalmente espressi su:
 - una *scala a intervalli*, in cui le differenze sono significative ma lo zero è convenzionale (ad esempio la temperatura in gradi Celsius);
 - una *scala a rapporti*, in cui esiste uno zero assoluto e sono significativi anche i rapporti tra valori (ad esempio peso, altezza, età).

Come vedremo questa classificazione non è puramente formale: la scelta delle statistiche descrittive e dei grafici (e più in là dei test inferenziali) dipende direttamente dal tipo di dato considerato. Un'analisi corretta inizia quindi sempre da un'attenta identificazione della natura delle variabili osservate.

Vogliamo aggiungere che nei dataset dobbiamo essere pronti a fronteggiare anche due importanti tipologie di dati:

- gli *identificatori*, che spesso anche chiamiamo **chiavi primarie** e che hanno il compito di individuare in maniera univoca il *record* (ossia, la riga) in questione (esempio tipico: il nostro codice fiscale);
- i *dati mancanti*, i *missing data*; sono problematici ma inevitabili, li codifichiamo usualmente con la sigla NA, *not available*, ed esiste tutto un filone di ricerca statistica che si pone come obiettivo quello di “gestire” i *missing data*.

■ **Vocabolario 3.1 — dataset completo.** Un dataset si dice **completo** quando non si osserva alcun **dato mancante**, NA.

3.1.2 Attenzione: garantire la qualità del dato



John Ioannidis, et al. How to survive the medical misinformation mess.
<https://onlinelibrary.wiley.com/doi/10.1111/eci.12834>

Nell'era delle decisioni basate su un'intelligenza artificiale in rapida ascesa, è imperativo essere consapevoli che la letteratura medica può avere un'attendibilità incerta; purtroppo, la maggior parte dei professionisti sanitari non è conscia di questo problema o manca delle competenze necessarie per valutare l'affidabilità e l'utilità delle evidenze mediche. Addirittura, secondo il professor Ioannidis, la maggior parte delle linee guida mediche (sulle quali molti clinici fanno affidamento per orientare le decisioni terapeutiche) non riconosce appieno la scarsa qualità dei dati su cui esse si basano: ci siamo già resi conto nella sezione precedente di quali siano i limiti del foglio elettronico e di come sia facilmente possibile propagare errori di rappresentazione o di codifica. Se pensiamo che nei laboratori e negli ospedali l'uso del foglio elettronico per la raccolta dati sia una prassi quotidiana, ci rendiamo conto che anche minime incongruenze nel collezionare i dati possono tradursi in errori pericolosi e pervasivi. Pertanto, la prima raccomandazione è ridurre al minimo il rischio di inserimento di dati errati: se il vostro team non ha esperienza nella gestione di database PHP e MySQL, è opportuno almeno imporre l'uso di **Google Moduli** per la raccolta, così da generare automaticamente il foglio elettronico dei dati:



Google Forms



Google Sheets

3.1.3 Indici di centralità e di dispersione per i dati qualitativi

Attività didattica 3.2 — Scheda. Indici di centralità e di dispersione per i dati qualitativi
<https://github.com/umgstat/biotec/blob/main/schede/scheda02.pdf>

La scheda ha l'obiettivo di imparare a calcolare l'indice di centralità (**moda**) e di dispersione (**eterogeneità di Gini**, **entropia di Shannon**) da una tabella di frequenze assolute.

1. importare in un nuovo foglio Google Sheets il dataset ZNF521.txt ;
2. create una tabella nella quale vengano calcolate le **frequenze assolute** e le **frequenze relative** delle basi azotate A, C, G e T;
3. determinate la **moda** della distribuzione di frequenze;
4. determinate i due indici di eterogeneità maggiormente utilizzati in letteratura, ossia l'(**eterogeneità di Gini** e l'**entropia di Shannon**).

Innanzitutto, prestiamo attenzione al fatto che il dataset ZNF521 è in formato .txt, e pertanto dobbiamo forse fare un po' di fatica nelle operazioni di importazione dei dati (magari, conviene per le prime volte aiutarsi con il Blocco Note o un qualunque altro editor di testo). Prepariamoci al compito, predisponendo uno schema di tabella come quella che vediamo qui sotto nelle colonne C e D:

	A	B	C	D	E
1	Q96K83				
2	A			frequenze	
3	T		basi azotate	assolute	
4	G		A		
5	T		C		
6	C		G		
7	T		T		
8	C				
9	G				
10	C				

Ora è arrivato il momento magico, quello di provare a chiedere a Gemini di aiutarci a creare il nostro primo Apps Script:

AI Utente

Ti chiedo di aiutarmi a creare una Apps Script che vada a leggere i dati contenuti nel Foglio 1 del mio Google Sheet attivo, che si chiama scheda2svolgimento; i dati sono contenuti nelle celle da A2 a A3937. Ti chiedo di contare quante lettere A, quante lettere C, quante lettere G e quante lettere T ci siano in quell'intervallo di celle, e dopo averle contate ti chiedo di scrivere come output il calcolo delle frequenze assolute ottenuto, rispettivamente nelle celle D4, D5, D6 e D7, colorandone lo sfondo di azzurro per indicarmi visivamente che sei riuscito a compiere la mia richiesta. Per favore, guidami passo per passo nell'esecuzione dell'Apps Script perché si tratta della mia prima esperienza.

Gemini ci guida passo per passo; vediamo come procedere.

Passo 1: Aprire l'editor di script

1. Apri il tuo file Google Sheets.
2. Nel menu in alto, clicca su Estensioni > Apps Script.
3. Si aprirà una nuova scheda del browser con un editor di codice. Vedrai una funzione predefinita chiamata `function myFunction() ...`. Puoi cancellare tutto il contenuto e incollarci il codice che trovi qui sotto.

Passo 2: Incollare il codice Copia e incolla questo script nell'editor:

```
codice 3.1 — JavaScript. function contaLettereSpecifiche() {  
  // 1. Ottieni il foglio di lavoro attivo chiamato "scheda2svolgimento"  
  var sheet = SpreadsheetApp.getActiveSpreadsheet().getSheetByName(  
    "scheda2svolgimento");  
  
  if (!sheet) {  
    SpreadsheetApp.getUi().alert("Errore: Il foglio ‘scheda2svolgimento’  
    non e’ stato trovato. Verifica il nome della scheda.");  
    return;  
  }  
  
  // 2. Leggi i dati dall'intervallo A2:A3937  
  var range = sheet.getRange("A2:A3937");  
  var values = range.getValues(); // Ottiene un array di valori  
  
  // 3. Inizializza i contatori  
  var counts = { 'A': 0, 'C': 0, 'G': 0, 'T': 0 };  
  
  // 4. Cicla tra le celle e conta le lettere  
  for (var i = 0; i < values.length; i++) {  
    var cellValue = String(values[i][0]).toUpperCase(); // Trasformiamo in  
    maiuscolo per sicurezza  
  
    // Controlliamo ogni carattere della stringa nella cella  
    for (var char of cellValue) {  
      if (counts.hasOwnProperty(char)) {  
        counts[char]++;  
      }  
    }  
  }  
  
  // 5. Scrivi i risultati nelle celle D4, D5, D6, D7  
  sheet.getRange("D4").setValue(counts['A']);  
  sheet.getRange("D5").setValue(counts['C']);  
  sheet.getRange("D6").setValue(counts['G']);  
  sheet.getRange("D7").setValue(counts['T']);  
  
  // 6. Imposta lo sfondo azzurro (codice esadecimale #ADD8E6)  
  sheet.getRange("D4:D7").setBackground("#ADD8E6");  
  
  // Messaggio di conferma opzionale  
  SpreadsheetApp.getUi().alert("Operazione completata! Lettere contate e
```

```
celle aggiornate.");
}
```

Passo 3: Salvare ed eseguire

1. Clicca sull'icona del **dischetto** (Salva) nella barra degli strumenti in alto. Dai un nome al progetto (es. "ContatoreLettere").
2. Assicurati che nel menu a tendina accanto al pulsante "Esegui" sia selezionata la funzione `contaLettereSpecifiche`.
3. Clicca sul pulsante **Esegui**.

Passo 4: Autorizzazioni (Importante) Poiché è la prima volta che esegui uno script su questo foglio, Google ti chiederà il permesso:

1. Ti apparirà una finestra "Autorizzazione richiesta". Clicca su **Esamina autorizzazioni**.
2. Scegli il tuo account Google.
3. Probabilmente vedrai un avviso: "Google non ha verificato questa app" (è normale, è uno script creato da te). Clicca su **Avanzate** (in basso a sinistra) e poi su **Vai a ContatoreLettere (non sicuro)**.
4. Clicca su **Consenti**.

Lo script verrà eseguito e vedrai i numeri apparire nelle celle **D4:D7** con lo sfondo azzurro!

Con una certa soddisfazione, noteremo che le quattro celle sono diventate azzurre e contengono proprio le frequenze che desideravamo ottenere:

	C	D
		frequenze
	basi azotate	assolute
	A	1136
	C	1012
	G	903
	T	885

Molto bene! Ora diventa tutto quasi banale: basta modificare il prompt e chiedere (con gentilezza) a Gemini di aiutarci a calcolare anche le **frequenze relative**, ossia, le percentuali. Fatto questo, possiamo chiedere un aiuto a Wikipedia per scoprire le definizioni dell'**indice di eterogeneità di Gini**, I e dell'**entropia di Shannon**, S , adattandole nel nostro caso:

$$I = 1 - (f_A^2 + f_C^2 + f_G^2 + f_T^2)$$

$$S = - (f_A \cdot \log_2(f_A) + f_C \cdot \log_2(f_C) + f_G \cdot \log_2(f_G) + f_T \cdot \log_2(f_T))$$

dove, banalmente, $f_A = 0.29$, $f_C = 0.26$, $f_G = 0.23$, $f_T = 0.22$ sono le quattro frequenze relative che avevamo appena calcolato.

Approfondimento 3.1 — disordine ed informazione. Possiamo provare a farci un'idea basilare del perché l'entropia di Shannon rappresenti una misura del disordine. Consideriamo, come faceva Claude Shannon, i bit (0 ed 1), e supponiamo che ci sia una percentuale x di zeri, ed $1 - x$ di uni. In tal caso la funzione S diventa:

$$S = - (x \cdot \log_2(x) + (1 - x) \cdot \log_2(1 - x))$$

e noi possiamo disegnarla con una calcolatrice grafica (ad esempio Geogebra, o Desmos). Osserveremo che se $x = 1 - x = 0.50$ abbiamo $S = 1$, ossia il massimo disordine, dunque

massima imprevedibilità e minima informazione. Viceversa se $x \approx 0$ oppure $x \approx 1$, allora $S \approx 0$, pochissimo disordine, dunque pochissima imprevedibilità, quindi molta prevedibilità e molta informazione.


3.1.4 Indici di centralità e di dispersione per i dati quantitativi

Attività didattica 3.3 — Scheda. Indici di centralità e di dispersione per i dati qualitativi
<https://github.com/umgstat/biotec/blob/main/schede/scheda03.pdf>

La scheda ha l'obiettivo di imparare a calcolare gli indici di centralità (**media** e **mediana**) e di dispersione (**deviazione standard** e **quartili**) da una variabile, numerica oppure ordinale.


1. importare in un nuovo foglio Google Sheets il dataset her2.ods ;
2. create delle tabelle nella quali vengano calcolati gli indici di centralità e di dispersione della etadiagnosi e immunoistochimica dei pazienti;

Adesso, prestiamo invece attenzione al fatto che il dataset her2 è in formato .ods; dunque dobbiamo fare un po' meno fatica di prima per importarlo in Google Sheets. Se vi viene comodo, potete continuare a usare Gemini ed Apps Script; oppure, potete digitare testualmente le funzioni MEDIA(), DEV.ST(), MEDIANA() oppure QUARTILI(), indicando l'intervallo dei dati come argomento delle funzioni (badando che la funzione che calcola i quartili necessita anche di conoscere di che quartile abbiamo bisogno)



Vale anche la pena osservare che invece di dividere i dati in quattro parti, avremmo potuto farlo in tre, o in dieci, o in cento parti uguali. Ecco dunque la definizione da ricordare:

■ **Vocabolario 3.2 — Quantili.** Quartili, terzili, decili e percentili sono esempi di **quantili**.



Vogliamo concludere questa scheda di attività precisando quale sia la funzione “che fa al caso nostro” per calcolare la deviazione standard, visto che il foglio elettronico ne propone almeno una dozzina di diverse. Teniamo presente che noi non siamo l'Istat che conosce tutti i dati della **popolazione**, ma tutti i nostri esperimenti si svolgono su (anche piuttosto piccoli) **campioni**, ossia un sottoinsieme di elementi tratti da un più ampio insieme detto, appunto, popolazione. Osserviamo attentamente i denominatori delle formule che definiscono le due diverse deviazioni standard:

$$\text{popolazione: } \sqrt{\frac{\sum_i (x_i - m)^2}{n}}, \text{ campione: } \sqrt{\frac{\sum_i (x_i - m)^2}{n-1}}$$

I libri di statistica matematica (ad esempio [17]) spiegano perfettamente perché questo sia opportuno, richiamando i concetti di “stimatore statistico corretto” e “stimatore statistico coerente”. Per capirlo facilmente vi invento una storiella. Supponiamo che Massimino Borellino al liceo abbia ricevuto rispettivamente il voto x ed il voto y nel primo e nel secondo compito di latino. Supponiamo che la mamma di Massimino scopra che il voto medio dei due compiti è 6. Riuscirebbe la mamma di Massimino a dedurre il voto x ed il voto y ? No, perché disporrebbe di una sola informazione rispetto ai due voti ignoti. Viceversa, supponiamo che la mamma di Massimino scopra dal registro elettronico che il voto medio dei due compiti è 6 e che la deviazione standard è 1.41. Riuscirebbe la mamma a scoprire i voti x ed il voto y ? Eh sì, eh:

The image shows a chalkboard with handwritten mathematical steps to solve for two unknowns, x and y, given their mean and standard deviation. The steps are as follows:

- Given: $x = ?$, $y = ?$
- Mean: $\frac{x+y}{2} = 6$
- Standard Deviation: $\sqrt{\frac{(x-6)^2 + (y-6)^2}{2-1}} = 1.41$
- From the mean equation: $y = 12 - x$
- Substitute y into the SD equation: $\sqrt{(x-6)^2 + (12-x-6)^2} = 1.41$
- Simplify: $\sqrt{(x-6)^2 + (6-x)^2} = 1.41$
- Square both sides: $(x-6)^2 + (6-x)^2 = 1.41^2$
- Simplify further: $2(x-6)^2 = 1.41^2$
- Solve for x: $x-6 = 1$
- Find x: $x = 1+6 = 7$
- Find y: $y = 12-7 = 5$

Dunque, ricapitolando. Se conosciamo la media abbiamo 1 informazione sull’andamento scolastico di Massimino; quindi per conoscere gli $n = 2$ voti ce ne manca ancora $(n - 1) = 2 - 1 = 1$ di informazione. Ecco l’intuizione: quel denominatore $(n - 1)$ rappresenta quante informazioni ci mancano per conoscere compiutamente tutti i valori della variabile in esame, partendo dalla loro media.

3.2 Descrizioni grafiche

3.2.1 Un’immagine vale più di mille parole

Attività didattica 3.4 — Scheda. Rappresentare graficamente i dati

<https://github.com/umgstat/biotec/blob/main/schede/scheda04.pdf>

La scheda ha l’obiettivo di impraticarsi con la moltitudine di grafici che abbiamo a disposizione per illustrare i nostri dati, qualitativi e quantitativi. I passi suggeriti sono:

1. visitare il sito di Yan Holtz, <https://r-graph-gallery.com/>
2. esplorare ad uno ad uno i grafici che vengono proposti
3. riutilizzare il foglio Google Sheets con il dataset `her2.ods`, concentrandosi sulle variabili `etadiagnosi`, `immunoistochimica` ed `ER`;
4. prepararsi alla discussione in aula circa l’abbinamento dei diversi grafici ai diversi tipi di dato numerico
5. realizzare un **boxplot** di `etadiagnosi`
6. realizzare un **istogramma** di `etadiagnosi`

Dopo aver esplorato le potenti capacità grafiche offerte dal linguaggio R, diamo un breve sguardo a quali di queste possibilità vengano implementate nel nostro foglio elettronico, tenendo presente che diversi tipi di variabili (nominali, ordinali, scalari) richiederanno rappresentazioni grafiche differenti:

- Diagrammi a torta, *pie chart*: adatti alle variabili di tipo qualitativo, espresse come frequenze assolute o relative
- Diagrammi a barre, *barplot*: adatti alle variabili di tipo quantitativo ordinale

- Istogrammi: adatti alle variabili di tipo quantitativo numerico

Se vogliamo essere super precisi, dedichiamo qualche minuto a chiarire la differenza tra il diagramma a barre ed all'istogramma: entrambi rientrano nella categoria “Distribution plots”, tuttavia, parlando di istogrammi, in essi l'altezza di ciascun blocco verticale non rappresenta sempre il valore della variabile di interesse (a meno che la larghezza del blocco sia unitaria), come accade invece per le barre di un bar chart. Inoltre, in un istogramma, la scala orizzontale è continua e non discreta, come nei bar chart. Infine, a differenza della larghezza delle barre, la larghezza dei blocchi di un istogramma *ha un significato*.

Concludiamo questa sezione ricordando anche il grafico denominato **box-plot**, nel quale le distanze tra le diverse parti del box indicano il grado di dispersione dei dati e la loro asimmetria dei dati; i baffi inoltre individuano le **code della distribuzione**.

Approfondimento 3.2 — outliers, ma a mensa. Cercate in rete cosa rappresentano i punti isolati che compaiono in certi boxplot e che vengono detti **outliers**, così come definiti da Tukey utilizzando l'intervallo interquartile. Cercate anche qualche riferimento attendibile sul fatto che tutte queste idee siano nate durante una pausa pranzo in una mensa universitaria.

3.2.2 Ricordiamoci sempre di rispettare i nostri interlocutori



Alla Katsnelson. Colour me better: fixing figures for colour blindness
<https://www.nature.com/articles/d41586-021-02696-z>

Non dobbiamo dimenticare che, a livello mondiale, la deficienza nella visione dei colori nei maschi è stimata essere intorno al 5–10% della popolazione: questo è un invito a preferire, quando possibile, l'adozione della cosiddetta palette di colori *viridis* nei grafici e a valorizzare le diverse informazioni anche tramite codifiche grafiche differenti (linee continue, tratteggiate, puntinate, ...).

Approfondimento 3.3 — cecità ai colori. Cercate in rete cosa sia la *palette* Viridis.





Figura 3.1: Un diagramma a torta con palette Viridis

3.3 Tutto chiaro?

.. no, no. Non è tutto chiaro, ma per oggi dobbiamo fermarci qui; ci manca ancora un ingrediente essenziale per discriminare su **quali** siano i grafici e gli indici numerici maggiormente appropriati per descrivere i dati del nostro esperimento. Ne parliamo meglio domani, nella sezione 5.1.

Tenere sotto controllo il caso

4	Il calcolo delle probabilità ci aiuta . . .	35
4.1	Le variabili aleatorie discrete	35
4.2	Due pensieri a confronto: von Mises e de Finetti	37
4.3	Simulare numeri casuali	38
4.4	Altre variabili aleatorie	40
4.5	Un grafico con il nome buffo: il Q-Q plot	46
5	Presentare i dati: conclusione	49
5.1	Siamo pronti: la famigerata Tabella 1	49
6	Rischio e probabilità	53
6.1	Probabilità a priori ed a posteriori	53
6.2	Quantificare il rischio	57



4. Il calcolo delle probabilità ci aiuta

In questo capitolo introduciamo le variabili aleatorie discrete attraverso semplici esperimenti ed esempi intuitivi, costruendo progressivamente il collegamento tra osservazioni empiriche e modelli probabilistici. Mettiamo inoltre a confronto le interpretazioni frequentista e soggettiva della probabilità, richiamando i contributi di von Mises e de Finetti. Mostriamo poi come il foglio di calcolo consenta di simulare fenomeni casuali, partendo dalla distribuzione uniforme e trasformandola in modelli più complessi. Queste simulazioni guidano il lettore alla comprensione di alcune distribuzioni di probabilità fondamentali per le scienze biomediche, tra cui la distribuzione normale, la lognormale, la distribuzione di Poisson e quella di Weibull, ciascuna associata a meccanismi differenti come effetti additivi, processi moltiplicativi, conteggio di eventi e tempi di attesa. Infine, introduciamo strumenti grafici diagnostici come il Q-Q plot, sottolineandone il ruolo nella valutazione delle ipotesi sulla distribuzione dei dati, e colleghiamo questi concetti alla pratica dell'analisi dei dati, inclusa la scelta tra approcci parametrici e non parametrici e l'interpretazione delle statistiche descrittive in contesti biomedici reali.

4.1 Le variabili aleatorie discrete

Approfondimento 4.1 — un bellissimo libro. Se avrete bisogno, un domani, di studiare meglio la probabilità, il mio libro consigliato è quello del professor Joe Blitzstein (Harvard University) e Jessica Hwang (Stanford University), intitolato *Introduction to Probability* [14]. Il professor Blitzstein offre anche un corso edX gratuito e una copia gratuita del suo libro.




Jonathan Blitzstein, Jessica Hwang. Introduction to Probability.
<https://projects.iq.harvard.edu/stat110/home>

Che voto vi darò all'esame? potrei fare così, lanciare questo dischetto, se esce il bianco vi do 30 e se esce nero vi metto 18. So che nessuno di noi è d'accordo con questa idea, ma tutti invece sembriamo essere d'accordo nel dire che la probabilità di avere 18 oppure 30 è la stessa, cinquanta per cento. Scriviamo dunque una tabella come questa

$$\begin{pmatrix} 18 & 30 \\ 0.50 & 0.50 \end{pmatrix}$$

Questa tabella, rappresenta un primo banale esempio di quello che i matematici chiamano **variabile aleatoria**: nella riga superiore abbiamo elencato tutti gli **eventi** possibili, mentre nella riga

sottostante abbiamo esplicitato i valori (percentuali) della **distribuzione di probabilità**, e anche per usare un altro termine, molto matematico, della **denistà di probabilità**. In particolare, questo primo esempio inerente il lancio di una moneta ha anche un nome preciso: si chiama **variabile aleatoria bernoulliana**, in onore di una numerosa famiglia di scienziati e giuristi svizzeri. Cosa c'è da aggiungere, c'è altro da dire a questo proposito? Beh, state pronti perché fra mezz'oretta demoliremo molte certezze.



Adesso invece stiamo vedendo questo sacchetto, con dentro tre palline arancioni, A, e tre palline bianche, B. Facciamo finta però di non averle viste, ed estraiamone a caso alcune, trascrivendo la sequenza:

A A B A B A B B A B B A B B B A B B

Se vi chiedessi di provare ad ipotizzare “come sia fatta” questa variabile aleatoria, potreste forse pensare che sia qualcosa di questo genere:

$$\begin{pmatrix} A & B \\ \frac{7}{18} & \frac{11}{18} \end{pmatrix}$$

Ma magari, se il sacchetto invece di essere trasparente fosse stato opaco, e io vi dicessi che se invece di essercene 6 di palline ce ne sono 5, di cui 2 bianche e 3 arancioni, magari non avreste dubbi a credermi. Anche qui, in questo caso, ci sarebbe molto da dire a tale proposito e dovremmo dire che quando ripetiamo più e più volte l'estrazione casuale di un evento distribuito secondo una variabile aleatoria bernoulliana, siamo in presenza di quella che si chiama **variabile aleatoria binomiale**. Ne ripareremo, ma per ora fermiamoci a pensare a questo altro esperimento.

Un esperimento inusuale. Inusuale, perché di solito non si trova nei libri introduttivi di calcolo delle probabilità. Da un sacchetto opaco, il cui contenuto ci è ignoto, estraggono una pallina **rossa**. La reimpussolano, ed estraggono un'altra pallina **rossa**. La reimpussolano, ed alla terza estrazione esce ancora una pallina **rossa**. Alla quarta estrazione, esce una pallina **verde**. Le estrazioni con reimpussolamento si susseguono con questa sequenza

R R R V R V V R R V V R R V R V R V V R
V V V R V R R R V R R V V R R R R

ma, alla trentottesima estrazione succede qualcosa di inaspettato, esce una pallina **azzurra**. Ecco che di colpo lo scenario cambia: non abbiamo più una variabile aleatoria binomiale, a quanto pare è capitato un **imprevisto**, qualcosa che non avremmo immaginato. Non riesco in effetti a descrivervi lo stupore che ebbimo tutti attorno all'anno 1996, in una classe di venticinque allievi, quando lanciai una moneta ma essa cadde al suolo rimanendo in perfetto equilibrio sul pavimento, appoggiata sul bordo, in verticale. Fenomeni di questo tipo sembrano creati apposta per “mettere in crisi” l'idea ingenua che ciascuno di noi si è fatto del concetto di probabilità. Discutiamo meglio.

4.2 Due pensieri a confronto: von Mises e de Finetti




Figura 4.1: Bruno de Finetti and Richard von Mises. Source: Wikipedia.

La carta che vedete rappresenta la situazione politica della mia città, Trieste, fino a poco più di centodieci anni fa: una città ai confini sud occidentali dell'impero austro-ungarico, la città di provenienza del matematico Bruno de Finetti. Ai confini nord orientali invece vediamo Leopoli / Leomberg, oggi Lviv, la città del matematico Richard von Mises. Quest'ultimo è considerato come il pensatore che fonda la **definizione frequentista** della probabilità, quella che ci ha permesso di ipotizzare la variabile aleatoria delle palline bianche ed arancioni di poco fa. Invece, per Bruno de Finetti (la sua frase famosissima è: *la probabilità non esiste*) vale la definizione di **probabilità soggettiva**: un evento ha un valore di probabilità nella misura in cui voi ed io siamo disposti a scommettere qualche soldo su quell'evento e di accettare la scommessa in maniera coerente, in modo che il "giocatore" ed il "banco" accettino senza perplessità di scambiarsi i ruoli. E io direi che ora valga la pena farsi quattro chiacchiere con Gemini, a tale proposito:

AI Utente

.. ma tu, in quanto LLM, effettui le tue valutazioni di probabilità seguendo l'approccio frequentista di Richard von Mises o quello soggettivo di Bruno de Finetti?

4.3 Simulare numeri casuali



I nostri computer posseggono delle routine molto efficienti per simulare la **variabile aleatoria uniforme**, ossia sono capaci di estrarre “a caso” un numero decimale del tipo “zero virgola ...”; o meglio, un numero x compreso nell’intervallo che va da zero ad 1 (ma attenzione, 0 compreso ed 1 escluso, $0 \leq x < 1$). Non siamo, dunque, più costretti a comperarci, come negli anni ‘50, il libro *A Million Random Digits* della Rand Corporation (ma se desiderate, lo trovate ancora in vendita su Amazon ...)

AI Utente

Aiutami a creare una Apps Script che agisca nel Foglio1 del mio Google Sheet attivo intitolato Simulare Numeri Casuali; crea nella cella A2 un numero casuale distribuito uniformemente, colorando la cella con lo sfondo di azzurro per indicarmi visivamente che sei riuscito a compiere la mia richiesta.

La nostra agente Gemini ci propone una soluzione funzionante, ma estremamente verbosa:

```
codice 4.1 — Generare Numeri Casuali. function generaNumeroCasuale() {
  // Ottieni il foglio di calcolo attivo
  var ss = SpreadsheetApp.getActiveSpreadsheet();

  // Verifica che il titolo del file sia corretto (opzionale)
  if (ss.getName() !== "Simulare Numeri Casuali") {
    Logger.log("Attenzione: il nome del file non corrisponde
      esattamente a ‘Simulare Numeri Casuali’");
  }

  // Accedi al foglio denominato "Foglio1"
  var sheet = ss.getSheetByName("Foglio1");

  if (sheet) {
    // Definisci la cella B2
    var cella = sheet.getRange("A2");

    // Genera un numero casuale (distribuzione uniforme tra 0 e 1)
    var numeroCasuale = Math.random();

    // Inserisci il numero nella cella
    cella.setValue(numeroCasuale);
  }
}
```

```
// Imposta il colore di sfondo in azzurro (Light Blue)
cella.setBackground("#ADD8E6");

SpreadsheetApp.getUi().alert("Operazione completata:
    numero generato e cella colorata!");
} else {
    SpreadsheetApp.getUi().alert("Errore: Non ho trovato
        un foglio chiamato 'Foglio1'.");
}
}
```

Avremmo potuto fare tutto da soli posizionandoci nella cella A2 e seguendo il menu Inserisci | Funzione | Matematica | Casuale, oppure digitando direttamente la funzione =CASUALE() all'interno della cella. Come vedete è una funzione che non ha alcun argomento in input, non dipende da nulla ma produce solamente un output.

Adesso, con alcune semplici trasformazioni lineari, riusciamo a simulare anche i dadi. Se volete, potete continuare con Gemini:



Utente

Aiutami a creare una Apps Script che agisca nel Foglio1 del mio Google Sheet attivo intitolato Simulare Numeri Casuali; leggi nella cella A2 il numero casuale distribuito uniformemente, e trasformalo nell'esito di un dado a 6 facce, scrivendo l'output nella cella B2 e colorando la cella con lo sfondo di azzurro per indicarmi visivamente che sei riuscito a compiere la mia richiesta.

ma il mio suggerimento è quello di provare a seguire questo ragionamento:

$$0 \leq x < 1$$

$$6 \cdot 0 \leq 6 \cdot x < 6 \cdot 1$$

$$0 \leq 6 \cdot x < 6$$

$$1 + 0 \leq 1 + 6 \cdot x < 1 + 6$$

$$1 \leq 1 + 6 \cdot x < 7$$

$$INT(1) \leq INT(1 + 6 \cdot x) < INT(7)$$

$$1 \leq INT(1 + 6 \cdot x) < 7$$

e dunque, se x rappresenta il numero casuale contenuto nella cella A2, inserendo nella cella B2 il comando:

$$= INT(1 + 6 * A2)$$

vi permette di simulare nella cella A2 il lancio di un dado a sei facce

■ **Attività 4.1 — dado a 20 facce.** Come possiamo modificare la funzione che abbiamo appena creato, per generare casualmente gli esiti di un dado a 20 facce? ■

Una nota conclusiva; osservate che, se provate a fare qualche operazione di copia ed incolla sul foglio elettronico, assisterete al fenomeno che si chiama **ricalcolo di una funzione volatile**: i numeri casuali “ballano” e vengono rigenerati. Per questo, nel prosieguo, vi consiglio di tenere a mente il fatto che esiste anche la possibilità di usare il comando Modifica | Incolla speciale | Solo valori, per fissare i risultati ottenuti.


4.4 Altre variabili aleatorie

Nei tempi andati, quando non esistevano ancora i computer, i matematici cercavano in ogni modo di evitare i metodi espliciti del calcolo combinatorio (proprio per non dover fare i conti, a mano, con carta e matita) qualora i medesimi risultati si potevano ottenere “per via analitica”, ossia, usando le funzioni, $y = f(x)$. Passiamo ora in rassegna quattro variabili aleatorie che rappresentano dei modelli molto comodi da utilizzare per studiare una varietà di problemi di natura biotecnologica.

4.4.1 La distribuzione normale

Attività didattica 4.1 — Scheda. La variabile aleatoria normale


<https://github.com/umgstat/biotec/blob/main/schede/scheda11A.pdf> ■



Questa scheda, basata sul lancio ripetuto di cinque dadi e sull’analisi delle somme ottenute, ha un obiettivo didattico ben preciso: ci guida verso la scoperta di una delle strutture più sorprendenti ed importanti della statistica, ovvero la distribuzione normale. In una prima fase, noi osserviamo una situazione molto elementare: ciascun dado fornisce un risultato casuale compreso tra 1 e 6, con uguale probabilità. Si tratta quindi delle variabili aleatorie discrete uniformi, che abbiamo visto nella sezione precente, ma che in questo caso sono **indipendenti** tra loro (se invece di lanciare i dadi tutti assieme li lancio uno alla volta, leggendo l’esito del dado che ho appena lanciato non sono in grado di prevedere l’esito del prossimo dado). Tuttavia, l’attenzione nostra non è rivolta ai singoli esiti, bensì alla loro *somma*. Questo passaggio è concettualmente cruciale: esso introduce un nuovo oggetto di studio, la cui distribuzione non è più uniforme.

Attraverso la raccolta dei dati sperimentali sul foglio elettronico, emerge infatti che alcune somme si presentano con maggiore frequenza rispetto ad altre. In particolare, i valori centrali risultano molto più probabili, mentre le somme estreme sono rare. Già con un numero limitato di osservazioni si intravede una struttura regolare: i dati tendono a disporsi attorno ad un valore centrale, in modo approssimativamente simmetrico. La seconda fase dell’attività, basata sulla simulazione tramite fogli di calcolo, consente di amplificare questo fenomeno. Ripetendo l’esperimento un gran numero di volte, osserviamo che l’istogramma delle somme assume una forma sempre

più stabile e regolare che, *dicitur, traditur*, ricorda una *curva a campana*. L'analisi descrittiva dei risultati, attraverso il calcolo della media e della deviazione standard, permette poi provare a descrivere in modo sintetico la distribuzione osservata. La media rappresenta il valore attorno al quale si concentrano i dati, mentre la deviazione standard misura la dispersione dei valori rispetto a tale centro. Nel caso specifico, si può osservare che la media empirica si avvicina al valore teorico atteso (pari a 17,5 per la somma di cinque dadi), evidenziando un primo collegamento tra modello matematico e osservazione sperimentale (linea tratteggiata blu, nelle due figure precedenti). Viceversa, la deviazione standard (che vale approssimativamente 3,8 per la somma di cinque dadi) consente di andare ad individuare nel modello teorico quelli che sono i due punti di flesso della curva (linee puntinate blu), laddove gli andamenti convessi delle **code della distribuzione** lasciano posto alla regione concava centrale.




Ulteriori dettagli importanti sono messi in luce dal grafico pubblicato alla pagina https://en.wikipedia.org/wiki/Standard_error di Wikipedia: nella regione centrale concava, quella compresa tra i due flessi, “normalmente” si raccolgono poco più del due terzi dei dati complessivi (il 68% circa), mentre la quasi totalità dei dati (il 99% abbondante) giace nell'intervallo compreso tra più e meno 3 deviazioni standard (il che non è mica sempre vero, per ogni fenomeno casuale – questa è una particolarità della distribuzione gaussiana, come ben sanno gli esperti di qualità aziendale che adottano la filosofia dei *six sigma*, delle sei deviazioni standard, per minimizzare il più possibili le riparazioni dei guasti delle loro produzioni in serie).

Il fatto inoltre che in corrispondenza del **quantile 0** il grafico raggiunga il suo punto di massimo, significa che nella distribuzione gaussiana la media coincide con la **moda**. Ed entrambe coincidono con la **mediana**, giacché il 50% dei dati cadono rispettivamente a sinistra ed a destra dello zero.

4.4.2 La distribuzione lognormale

Attività didattica 4.2 — Scheda. La variabile aleatoria log-normale

<https://github.com/umgstat/biotec/blob/main/schede/scheda11B.pdf>



Questa scheda propone una modifica dell'esperienza precedente sulla distribuzione normale: al posto della somma dei risultati di più variabili aleatorie, si considera il loro *prodotto*. Nella

fase iniziale, lavoriamo ancora con variabili aleatorie discrete ed indipendenti: i risultati ottenuti dal lancio di quattro dadi a sei facce. Come nel caso precedente, ciascun dado produce valori uniformemente distribuiti tra 1 e 6. Dicevamo però che l'oggetto di interesse non è più la somma dei punteggi, bensì il loro prodotto. Questo cambiamento ha conseguenze rilevanti sul comportamento della variabile risultante. A differenza della somma, che tende a produrre distribuzioni simmetriche, il prodotto genera valori fortemente *asimmetrici*. Già dai primi dati sperimentali si osserva che:

- i valori piccoli sono relativamente frequenti;
- i valori grandi sono più rari ma possibili;
- il grafico della distribuzione presenta una coda molto allungata verso destra.

In altre parole, l'istogramma del prodotto non è simmetrico, ma mostra una chiara *asimmetria positiva*. La fase di simulazione, realizzata attraverso l'uso del foglio elettronico, permette di amplificare e stabilizzare queste osservazioni. Il punto chiave di questa attività è comprendere che tale comportamento non è casuale, ma riflette una struttura matematica precisa. Per interpretarla, si introduce un'idea fondamentale: invece di osservare direttamente il prodotto, si considera il logaritmo del prodotto.

Se indichiamo con X_1, X_2, X_3, X_4 i risultati dei quattro dadi e con


$$P = X_1 \cdot X_2 \cdot X_3 \cdot X_4$$

il loro prodotto, allora vale la relazione:

$$\log P = \log X_1 + \log X_2 + \log X_3 + \log X_4.$$

Questa osservazione è decisiva: il logaritmo del prodotto trasforma il problema in una *somma* di variabili aleatorie. Di conseguenza, si può applicare lo stesso principio incontrato nello studio della distribuzione normale: la somma di variabili indipendenti tende ad assumere una forma approssimativamente normale; ossia, che la variabile $\log P$ è approssimativamente distribuita secondo una legge gaussiana. Ecco perché diciamo che la variabile originale P si distribuisce secondo una *distribuzione lognormale*.

L'analisi descrittiva dei dati empirici, attraverso il calcolo della media e della deviazione standard del prodotto, consente di descrivere sinteticamente la distribuzione osservata, ma mette anche in evidenza una differenza importante rispetto al caso normale: in presenza di asimmetria, la **media** è influenzata dai valori estremi e non coincide con il "centro della distribuzione", il centro inteso in senso visivo, e che rappresenta la **mediana** della distribuzione. Ancora più schiacciato verso sinistra appare il punto di massimo della curva (che ricordiamo si chiama **densità di probabilità**), ossia la **moda**.



Distribution of BMI values. A histogram of the BMI values (expressed in kilograms per square meter) among the 108 927 hospitalization


L'esperienza conduce quindi a una generalizzazione importante: mentre la distribuzione normale è associata a fenomeni additivi, la distribuzione lognormale rappresenta un modello naturale per

fenomeni di tipo moltiplicativo [3]. E come vediamo nella figura nera [2] qui sopra, la distribuzione dei valori di indice di massa corporea (BMI) mostra una distribuzione chiaramente asimmetrica: la maggior parte delle osservazioni si concentra su valori medio-bassi, mentre una coda relativamente lunga si estende verso destra, corrispondente a valori elevati di BMI nelle persone obese (il famoso *obesity paradox in acute heart failure*). Matematicamente, un'analisi più rigorosa mostrerebbe che il BMI non è né normalmente distribuito né lognormalmente distribuito. In effetti, la distribuzione esatta è un oggetto più complesso, privo di un nome standard e raramente utilizzato in forma esplicita nelle applicazioni.

4.4.3 La distribuzione di Poisson

Attività didattica 4.3 — Scheda. La variabile aleatoria di Poisson

<https://github.com/umgstat/biotec/blob/main/schede/scheda11C.pdf>



Dopo aver analizzato il comportamento di somme e prodotti di variabili aleatorie, è naturale considerare un ulteriore tipo di fenomeno casuale: il *conteggio di eventi*. In molti contesti reali, l'interesse non è rivolto al valore assunto da una grandezza continua, bensì al numero di volte in cui un certo evento si verifica in un intervallo prefissato. Questa scheda ha l'obiettivo di far emergere, in modo sperimentale e intuitivo, la struttura della distribuzione di Poisson come modello per il conteggio di **eventi rari**. Si considerano trenta dadi a venti facce, ciascuno dei quali produce ad ogni lancio un risultato intero compreso tra 1 e 20, con uguale probabilità. L'attenzione non è rivolta al valore complessivo dei punteggi, bensì a un evento specifico: l'uscita del valore 1.

Per ciascun lancio simultaneo dei trenta dadi, si procede dunque a identificare quelli che hanno prodotto come esito il valore 1. Ogni dado può essere interpretato come una distribuzione bernoulliana (ne parlavamo all'inizio, nella sezione 4.1) in cui:

- il "successo" è l'uscita del valore 1;
- la probabilità di successo è pari a $p = \frac{1}{20}$, quindi piccola.

La quantità di interesse è il numero totale di successi osservati in ciascun lancio complessivo, ovvero il numero di dadi che mostrano il valore 1. Tale numero viene registrato e trascritto, insieme agli esiti dei singoli dadi, in un foglio di calcolo. Ripetendo l'esperimento un numero limitato di volte, si ottengono dati grezzi che permettono una prima esplorazione del fenomeno. Tuttavia, per evidenziare con maggiore chiarezza la struttura probabilistica sottostante, l'esperimento viene successivamente esteso mediante simulazione, utilizzando il solito generatore di numeri pseudocasuali e ripetendo il processo un gran numero di volte (ad esempio mille o più). Per ciascuna simulazione, si verifica per ogni dado il verificarsi o meno dell'evento di interesse (uscita del valore 1), e si calcola il numero totale di successi. In questo modo si costruisce una collezione di osservazioni della variabile aleatoria


X = numero di dadi che mostrano il valore 1.

Dal punto di vista teorico, X può essere visto come somma di 30 variabili di Bernoulli indipendenti, ciascuna con probabilità di successo $p = \frac{1}{20}$. Pertanto, X segue esattamente una distribuzione binomiale, quella della sezione 4.1. Tuttavia, poiché il numero di prove è relativamente elevato e la probabilità di successo è piccola, ci si trova nella situazione tipica in cui la distribuzione binomiale può essere approssimata da una funzione esponenziale, con un trucchetto ben noto a chi ha dato l'esame di Analisi 1 all'università. Anche in questo caso l'istogramma dei valori osservati per X , costruito a partire dai dati simulati, permette di confrontare la distribuzione empirica con il modello teorico. Si osserva in particolare che:

- i valori più frequenti sono piccoli (0, 1, 2, talvolta 3);
- valori più elevati diventano rapidamente rari;
- la distribuzione è asimmetrica, con coda verso destra.

Il calcolo della media e della deviazione standard consente inoltre di verificare una proprietà caratteristica della distribuzione di Poisson, ossia che esse coincidono per tramite della radice quadrata (infatti, la media $\lambda \approx 30 \cdot \frac{1}{20} = 1,5$ e la deviazione standard vale circa $\sqrt{1,5} \approx 1,2$).

Come esempio tipico dell'ambito biomedico, consideriamo un esempio tratto da Daniel Zips (*Tumour growth and response to radiation*, in [15]), relativa alla probabilità di controllo locale del tumore (Tumour Control Probability, TCP). Quando si “idealizza” un tessuto tumorale come una matrice di celle, la probabilità di controllo locale può essere descritta in termini statistici: in particolare, essa è modellabile attraverso una distribuzione di Poisson che rappresenta il numero di cellule tumorali clonogeniche sopravvissute al trattamento radioterapico. L'idea alla base di questo modello può essere illustrata nel modo seguente: immaginiamo che una determinata dose di radiazione produca un certo numero di “colpi letali” distribuiti in maniera casuale all'interno della popolazione cellulare. Alcune cellule tumorali (celle colore arancione) riceveranno uno o più colpi letali, mentre altre potrebbero sopravvivere e quindi dare origine a una recidiva locale del tumore, necessitando quindi di una nuova dose di radiazione.



In questo contesto, la distribuzione di Poisson fornisce un modello naturale per descrivere il numero di cellule sopravvissute. Se indichiamo con m il numero medio di colpi letali per cellula, allora, secondo le proprietà della distribuzione di Poisson, la probabilità che una cellula non riceva alcun colpo letale è data da $P(0) = e^{-m}$. Ne segue che, se la dose di radiazione è tale da produrre in media $m = 1$ colpo letale per ogni cellula clonogenica, allora la frazione di cellule sopravvissute sarà pari a $e^{-1} \approx 0.37 = \lambda$, ossia circa il 37%.

Approfondimento 4.2 — un bellissimo libro. Vi invito a confrontare l’approccio che abbiamo seguito per presentare le variabili aleatorie in questa nostra dispensa, con quello del tutto innovativo ed originale degli autori del seguente libro:




Susan Holmes, Wolfgang Huber. Modern Statistics for Modern Biology
<https://www.huber.embl.de/msmb/Chap-Generative.html>

come vedrete, lì la distribuzione di Poisson la fa da padrona: in fin dei conti, in biologia e nelle biotecnologie i ricercatori passano il loro tempo a contare le cose che vedono sotto cappa o con i loro potenti microscopi.

4.4.4 La distribuzione di Weibull

Attività didattica 4.4 — Scheda. La variabile aleatoria di Weibull

<https://github.com/umgstat/biotec/blob/main/schede/scheda11D.pdf>



L’ultima attività proposta introduce una nuova prospettiva nella modellizzazione dei fenomeni casuali: non si tratta più di descrivere somme, prodotti o conteggi, ma di studiare il *tempo fino al verificarsi di un evento*, o più in generale il comportamento di un sistema esposto a un rischio che evolve nel tempo.

L’esperimento proposto introduce in modo concreto il concetto di *tempo di primo superamento* di una soglia variabile, concetto centrale nell’analisi dei tempi di sopravvivenza e nei modelli di affidabilità. Si consideri una sequenza di soglie s intere decrescenti $40, 39, 38, \dots, 2, 1$ che rappresentano livelli progressivamente più facili da superare. Tali soglie possono essere interpretate come una misura di rischio o di difficoltà che evolve nel tempo: inizialmente molto elevata, e successivamente sempre più bassa. Per ciascun istante $t = 1, 2, \dots, 40$, si esegue un lancio indipendente di due dadi a 20 facce e si calcola la somma dei risultati ottenuti. Si ottiene così una successione di variabili aleatorie indipendenti, $S_1, S_2, \dots, S_{40}$, dove ciascuna variabile rappresenta la “prestazione” del sistema al tempo t . In ogni istante si confronta il valore osservato S_t con la soglia s corrispondente. L’evento di interesse si verifica quando, per la prima volta, la somma dei risultati supera la soglia: $S_t > \text{soglia}(t)$. Si definisce quindi il *tempo di primo superamento* come $T = \min\{t : S_t > \text{soglia}(t)\}$. Tale quantità rappresenta il numero di tentativi necessari affinché il sistema superi la condizione imposta dalla soglia. Per costruzione, questo tempo è ovviamente sempre finito: infatti, poiché la somma dei due dadi è sempre almeno pari a 2, e l’ultima soglia vale 1, prima o poi la condizione $S_t > \text{soglia}(t)$ deve necessariamente verificarsi.

Ripetendo l’intero esperimento un gran numero di volte, si ottiene una collezione di osservazioni della variabile aleatoria T , che descrive la distribuzione dei tempi di primo superamento. Alcune realizzazioni corrisponderanno a tempi brevi (superamento precoce), mentre altre richiederanno più tentativi. Dal punto di vista concettuale, questo meccanismo modella un sistema soggetto a

un rischio variabile nel tempo: inizialmente il superamento è difficile (soglia alta), ma diventa progressivamente più probabile. La variabile T rappresenta quindi un tempo di sopravvivenza in presenza di un rischio che evolve nel tempo. Distribuzioni di questo tipo sono tipicamente descritte dalla **variabile aleatoria di Weibull**, che costituisce uno dei modelli fondamentali nell'analisi dei tempi di vita, o della sopravvivenza. In particolare, la forma della distribuzione riflette il fatto che la probabilità di superare la soglia cresce nel tempo ('rischio crescente', avremo modo di parlarne meglio alla fine della mattinata), dando luogo a una struttura asimmetrica con coda verso destra.

Anche la distribuzione di Weibull possiede delle "parentele" matematiche con la distribuzione gaussiana; e mentre la seconda era caratterizzata da due elementi caratteristici, due **parametri** (la media e la deviazione standard), la prima è caratterizzata da:

- un parametro di **scala**, che determina l'ordine di grandezza dei tempi osservati;
- un parametro di **forma**, che descrive il modo in cui il rischio evolve nel tempo.

In particolare, se il parametro di forma è minore di 1, il rischio diminuisce nel tempo (esempio: mortalità infantile nei Paesi occidentali); se è uguale a 1, il rischio è costante (probabilità di un salmone che risale il corso di un fiume di essere catturato da un orso); se è maggiore di 1, il rischio aumenta nel tempo (esempio: mortalità degli esseri viventi).

4.5 Un grafico con il nome buffo: il Q-Q plot


AI Utente

Mi insegni come posso generare nel foglio elettronico Google Sheet una colonna di numeri casuali distribuiti in maniera gaussiana?

Abbiamo imparato che con la funzione CASUALE() possiamo generare numeri (pseudo)casuali che distribuiti uniformemente sull'intervallo $0 \leq x < 1$. I fogli elettronici possiedono anche delle funzioni apposite che riescono a "trasformare" questi numeri in tutte le altre distribuzioni casuali. È questo il caso della funzione INV.NORM.ST(), la funzione "inversa della normale standard", la quale trasforma appunto un numero $0 \leq x < 1$ in un altro numero x ; e se al posto di generarne uno solo di questi ne generiamo un centinaio, un migliaio, e chiediamo di raffigurarli con un istogramma, osserveremo immediatamente che essi si caratterizzano per il loro tipico andamento a campana, con **media 0** e **deviazione standard 1** (i due parametri che definiscono, appunto, la variabile aleatoria normale standard).

Attività didattica 4.5 — Scheda. La variabile aleatoria di Weibull

<https://github.com/umgstat/biotec/blob/main/schede/scheda11D.pdf>



Siamo pronti per creare il nostro primo Q-Q plot. Riprendiamo il nostro precedente foglio Google Sheets con il dataset her2.ods, e creiamo una colonna di numeri casuali gaussiani standard,

sfruttando appunto le funzioni CASUALE() e INV.NORM.ST(), come vediamo a sinistra nella figura. Copiamo la colonna di numeri casuali gaussiani ed incolliamola in una nuova colonna “in maniera speciale” (*solo numeri*), Modifica | Incolla speciale | Solo valori. Adesso, riordiniamo questa nuova colonna in maniera crescente, attribuendole per esempio il nome SORTnormali; copiamo ed incolliamo accanto etadiagnosi, riordiniamo anche questa in maniera crescente per esempio con il nome SORTetadiagnosi. Eseguiamo un diagramma a dispersione (aggiungendo eventualmente con il menu Personalizza | Serie | Linea di tendenza una **retta di regressione** (ahimè, non riusciamo ad essere più precisi in questa sede, ne riparliamo una prossima volta).

Ora, questo **grafico Quantile-Quantile** rappresenta uno “strumento diagnostico grafico” che ci consente di valutare se una colonna di dati campionari segue la distribuzione normale, in base a queste semplici decisioni “empiriche”:

- **Andamento Lineare:** Se i dati sono distribuiti normalmente, i punti nel grafico si disporranno approssimativamente lungo una linea retta.
- **Deviazioni nelle Code:** Se i punti alle estremità si allontanano dalla retta verso l’alto o verso il basso, siamo in presenza di “*code pesanti*” (presenza di outlier); una curvatura sistematica (ad esempio, una forma concava o convessa come una banana) o una doppia curvatura (ad esempio, una forma a serpente) suggerisce che la distribuzione dei dati è fortemente asimmetrica rispetto alla media, e quindi verosimilmente i dati non si conformano all’ipotesi di normalità.


In conclusione, sebbene esistano procedure formali delle quali adesso non vogliamo parlare, l’ispezione visiva del Q-Q plot è preferibile in ambito clinico e biologico poiché vi consente di distinguere tra lievi scostamenti irrilevanti o violazioni gravi della normalità. Vediamo ora come questo ci torna immediatamente utile.

5. Presentare i dati: conclusione

In questa Sezione concludiamo il discorso che avevamo lasciato ieri in sospeso: come riassumere i dati numerici e come presentarli ai lettori, sia in forma tabellare sia in forma grafica.

5.1 Siamo pronti: la famigerata Tabella 1

Abbiamo ora sottomano tutti gli ingredienti per rispondere ad una domanda cruciale : per descrivere (e, conseguentemente analizzare) i nostri dati, seguiremo un **approccio parametrico** o **non parametrico**? Seguiamo questo albero decisionale:



Se siamo in presenza di misure numeriche, come accadeva per l'etadiagnosi nel dataset `her2.ods`, le quali si dispongono in maniera ragionevolmente rettilinea nel Q-Q plot, allora possiamo scegliere l'**approccio parametrico**; riassumeremo i dati indicando la media e la deviazione standard e li raffigureremo ai nostri interlocutori con un istogramma. Viceversa, in tutti gli altri casi, seguiremo un **approccio non parametrico** basandoci sui *ranks*, sui "ranghi", classificando i dati con le mediane, i quartili, le frequenze, ed adattando i grafici a questo approccio, come indicato nella figura qui sopra.

5.1.1 Perché la Tabella 1 è famigerata?

Ora avremmo bisogno di parlare con gli esperti di filosofia, di epistemologia, per riuscire a cogliere un concetto elusivo, che però coinvolge una delle distinzioni fondamentali (o forse “la distinzione fondamentale”) tra la matematica e la biostatistica, e che risiede nel “valore intrinseco” del numero, nella sua “ontologia”. In matematica, il valore $x = 2$ è un’entità astratta, un punto in un insieme numerico la cui rilevanza è definita da proprietà logiche e strutturali, tanto quanto il valore $x = 200$. In biostatistica, al contrario, il numero non è mai “nudo”: esso possiede un “quid”, una *semantica*, ovvero un significato che dipende indissolubilmente dal contesto in cui è generato e osservato. Se cammino per la via e vedo un paio di scarpe abbandonate in un angolo vicino ai



cassonetti dell’immondizia, o se invece alzo gli occhi e le vedo appese ai fili del telefono o della illuminazione stradale, le cose cambiano sostanzialmente. Se analizzassimo il fenomeno in termini puramente *matematici*, vedremmo solo scarpe abbandonate senza un proprietario. Al contrario, la lettura *statistica* di questo dato cambia radicalmente in base al contesto socio-ambientale, perché il fenomeno dello *shoefiti* può rappresentare un segnale di degrado o criminalità, in determinati contesti urbani, indicando il confine di una piazza di spaccio; oppure, in un contesto goliardico universitario, celebra la fine del percorso di studi, trasformandosi in un simbolo di festa e traguardo raggiunto.

In biostatistica accade lo stesso. Un valore numerico è sempre “informativo” e richiede un’interpretazione semantica. Per questo dobbiamo redigere la Tabella 1 per far cogliere ai lettori l’essenza di ciò che stiamo studiando e descrivendo, per aiutare a cogliere la tipicità dei dati ed isolare errori di laboratorio, rumori, varianti biologiche rare ma fisiologiche, l’esordio di una patologia. Cerco di darvi un paio di esempi per farmi capire meglio.

Table 1. Characteristics of Infants with Very Low Birth Weight and Those Born at Term.*		
Characteristic	Study Participants	Study Nonparticipants
Very low birth weight		
No. of subjects	166	89
Gestational age — wk	29.17±2.22	29.17±2.68
Birth weight — g	1120±221	1130±209

Guardiamo questa Tabella 1, apparsa sul New England, un giornalone, come saprete. Vedete che ci si occupa di neonatologia, e guardiamo le descrizioni di le settimane di Gestational age ed i grammi di Birth weight. Vedete che in entrambi i casi, ed in entrambi i due gruppi di studio, viene usato il simbolo $\pm$, verosimilmente media più o meno deviazione standard. Una scrittura di questo tipo sottointende che stiamo dando una descrizione dei dati assumendo un approccio parametrico, e dunque implicitamente che vi sia, sottostante, una distribuzione gaussiana di dati. Ma, come abbiamo appena imparato nel paragrafo 4.4.4, di solito i tempi seguono leggi aleatorie fortemente asimmetriche, e quindi sarebbe stato logico aspettarsi di parlare di tempi mediani, e non di tempi medi. Strano, no?

Continuiamo. La durata media della Gestational age è di 29.17 settimane, e non di 29.16 oppure di 29.18 (altrimenti, gli autori avrebbero scritto 29.2 settimane, usando una sola cifra

decimale). Quindi, significa che ci appare rilevante prendere in considerazione il tempo di 0.01 settimane. Ma siccome in un una settimana, ossia in sette giorni, contiamo 168 ore, valutare differenze di 0.01 settimane significa implicitamente che si ritiene rilevante una variazioni che accade in 1 ora e 41 minuti. Il che, considerando che l'età gestazionale (spesso stimata sul ricordo della neomamma che ipotizza per tutte le donne cicli mestruali regolari di 28 giorni) misurata tramite la lunghezza biometrica fetale vertice-sacro (CRL) offre un margine di errore tipico di ± 3 -5 giorni, capite bene che sembra come se si voglia misurare con il calibro il perimetro del campus di Germaneto. Analogamente, il Birth weight: se scriviamo 1120 ± 221 , ossia con la precisione di 1 milligrammo, e se sappiamo cheè il peso dell'ala di una zanzara è circa 1 milligrammo, concludiamo che ... finite voi la frase.

	n	Mean (SD) g/ week	Median g/ week
1994	362	128 (147)	79
1996	363	112 (110)	78

Guardiamo adesso il FinBalt survey, in cui ci si occupa del consumo di alcol tra i giovani scandinavi durante il week end. Se i ricercatori, dopo aver osservato la forma della distribuzione dei dati con il Q-Q plot, hanno deciso che nel primo studio i valori si comportavano in modo simmetrico e unimodale, e che quindi la notazione $\mu(\sigma)$ (media e deviazione standard) fosse una scelta appropriata per riassumere la distribuzione, ci verrebbe da concludere che in Estonia e in Finlandia durante il weekend esistano più di un 15% di bevitori il cui organismo non consuma, ma *produce* alcol, dato che $128 - 147 = -19$... Strano, no?

Results
Reliability of automated analysis
For the analysis of the datasets, the two expert analysts manually detected, on average, 4,562 (range 4,439 to 4,686) events (EAdi or P_V events). ICCs for the NeuroSync_{MANU}



Un ultimo punto, cruciale nella corretta comunicazione dei risultati statistici riguarda il mai troppo citato principio del Rasoio di Occam *Frustra fit per plura quod potest fieri per pauciora*, che a ben vedere sarebbe in effetti la versione latina di *K.I.S.S. = keep it simple, stupid!*; non ha senso fornire un numero di statistiche descrittive superiore alla dimensione dei dati da comunicare. Ecco l'esempio divertente: supponiamo che l'Esperto A analizzi 4439 immagini e l'Esperto B ne analizzi 4686. Queste sono le **due** informazioni da comunicare al lettore: come scriverle in un


articolo scientifico? Lì sopra la soluzione adottata da Christer Sinderby e collaboratori [5]: fornirne **tre**, di informazioni. Strano, no?

6. Rischio e probabilità

In questo Capitolo impareremo come riassumere dati numerici e non numerici e come presentarli ai lettori, sia in forma tabellare sia in forma grafica. Discuteremo inoltre il modo corretto di farlo, presentando alcuni errori tipici presenti in letteratura.

6.1 Probabilità a priori ed a posteriori

Immaginiamo di avere davanti a noi due sacchetti, A e B, e di dover partecipare ad un gioco in cui siamo completamente bendati. Dentro questi sacchetti ci sono dei dadi, ma sono dadi speciali e diversi tra loro. Nel sacchetto A ci sono due classici dadi a sei facce, mentre nel sacchetto B c'è un unico grande dado a dodici facce. Il gioco funziona così: una persona estrae segretamente un sacchetto e inizia a lanciare i dadi che trova dentro per molte volte di seguito, diciamo venti, segnando ogni volta il risultato su una lavagna. Se ha in mano il Sacchetto A, lancerà i due dadi da sei e ci leggerà la loro somma; se invece ha il Sacchetto B, lancerà il dado da dodici e ci leggerà di volta in volta il numero uscito. Noi, da bendati, non possiamo vedere quale sacchetto è stato scelto, ma possiamo sentire i numeri che vengono letti ad alta voce, uno dopo l'altro. Il nostro obiettivo è fare i detective: dobbiamo interpretare la sequenza di numeri che compare sulla lavagna e, usando la logica (e un pizzico di teoria della probabilità), indovinare da quale sacchetto provengono.



Invece di affidarci ad una persona, usiamo il computer ed il linguaggio R, anzi, usiamo per semplicità la risorsa online <https://rdrr.io/snippets/> di cui parlavamo all'inizio della dispensa, nella sezione 1.3.1. Come vedrete, il tutto diventa abbastanza semplice e si risolve in una banale operazione di copia e incolla: si copia il testo dei comandi, si incollano nello "spazio bianco" indicato dalla freccia tratteggiata, e poi si schiaccia il pulsante verde (come

dicono gli studenti, "si fa correre"). L'output desiderato compare, dopo qualche istante, in

una sezione sottostante di colore giallino. Il codice che useremo, e che trovate all'indirizzo <https://github.com/umgstat/biotec/blob/main/codici/bayes.R>, fa esattamente questo: simula al computer questo scenario e ci mostra i numeri proprio come se stessero uscendo in tempo reale, sfida dopo sfida, per vedere se siamo capaci di scoprire il trucco. Per garantire che l'esperimento sia ripetibile con gli stessi identici risultati a fini didattici, il codice si serve della funzione `set.seed`, che fissa lo stato del generatore di numeri pseudo-casuali di R.

codice 6.1 — bayes.R. ■

```
# Estrarre una lettera casuale tra "A" e "B"
set.seed(3456)
sample(LETTERS[1:2], size = 1)

# Sacchetto "A", due dadi a 6 facce
D6_1 = 1:6
D6_2 = 1:6
set.seed(3456)
esito <- sample(D6_1, size = 20, replace = TRUE) +
  sample(D6_2, size = 20, replace = TRUE)
cat(sapply(1:20, function(i) paste(esito[1:i], collapse = " ")),
    sep = "\n\n")

# Sacchetto "B", un dado a 12 facce
D12 = 1:12
set.seed(3456)
esito <- sample(D12, size = 20, replace = TRUE)
cat(sapply(1:20, function(i) paste(esito[1:i], collapse = " ")),
    sep = "\n\n")
```

■

Nel primo scenario, associato al Sacchetto A, la simulazione prevede il lancio simultaneo di due dadi tradizionali a sei facce per venti volte consecutive:

```
, size = 20,
```

Da un punto di vista matematico, l'esito di ogni lancio è definito dalla somma di due variabili casuali discrete e indipendenti, ciascuna con valori compresi tra uno e sei. Questo processo genera una distribuzione di probabilità non uniforme nell'intervallo da due a dodici. Il valore sette rappresenta la combinazione più probabile, verificabile con una frequenza di sei casi su trentasei, mentre gli estremi due e dodici risultano i meno probabili. Una caratteristica cruciale di questo modello è l'impossibilità teorica di ottenere il valore uno come risultato della somma.

Al contrario, lo scenario del Sacchetto B simula il lancio di un singolo dado a dodici facce, ripetuto anch'esso per venti volte:

```
sample(D12, size = 20, replace = TRUE)
```

In questo caso, l'esito è regolato da una distribuzione uniforme, in cui ogni numero intero compreso nel range da uno a dodici possiede l'esatta stessa probabilità di verificarsi, pari a un dodicesimo. La differenza fondamentale rispetto al modello precedente risiede nel fatto che il numero uno è un esito perfettamente ammissibile e frequente quanto gli altri.

La parte finale del codice è piuttosto tecnica e si occupa di elaborare queste sequenze numeriche per mostrarle all'utente in modo progressivo attraverso le funzioni `sapply` e `cat`. Questa visualizzazione cumulativa serve a simulare lo svolgimento del gioco in tempo reale, permettendo a noi "osservatori bendati" di analizzare i dati man mano che si accumulano.

Iniziamo dunque con il far eseguire le prime tre righe di codice, per estrarre il sacchetto segreto:

```
# Estrarre una lettera casuale tra "A" e "B"
set.seed(3456)
sample(LETTERS[1:2], size = 1)
```

ed otteniamo la lettera segreta:

```
[1] "B"
```

A questo punto, copiamo ed incolliamo solamente l'ultimo "pezzo" di codice,

```
# Sacchetto "B", un dado a 12 facce
D12 = 1:12
set.seed(3456)
esito <- sample(D12, size = 20, replace = TRUE)
# lapply(1:20, function(i) esito[1:i])
# oppure
cat(sapply(1:20, function(i) paste(esito[1:i], collapse = " ")), sep = "\n\n")
```

ed otteniamo (verosimilmente fino a che i programmatori di R non decidano di cambiare gli algoritmi di generazione dei numeri pseudocasuali) una sequenza di questo tipo:

```
2
```

```
2 10
```

```
2 10 6
```

```
2 10 6 5
```

```
2 10 6 5 8
```

```
2 10 6 5 8 12
```

```
2 10 6 5 8 12 12
```

```
2 10 6 5 8 12 12 3
```

```
2 10 6 5 8 12 12 3 5
```

```
2 10 6 5 8 12 12 3 5 7
```

```
2 10 6 5 8 12 12 3 5 7 7
```

```
2 10 6 5 8 12 12 3 5 7 7 11
```

2 10 6 5 8 12 12 3 5 7 7 11 8

2 10 6 5 8 12 12 3 5 7 7 11 8 7

2 10 6 5 8 12 12 3 5 7 7 11 8 7 1

. . .

A questo punto, facciamo entrare in campo la nostra amica AI, e chiediamole:


AI Utente

Avrei bisogno del tuo aiuto per “capire” come funziona il calcolo delle probabilità. Il mio avversario possiede un sacchetto A che contiene due dadi a 6 facce, ed un sacchetto B che contiene un dado a 12 facce. Egli estrae a caso un sacchetto, ma io non so di quale dei due si tratti. Io devo indovinare se sia il sacchetto A o il sacchetto B, sulla base delle informazioni che mi verranno date via via, relativamente all’esito del lancio dei/del dadi/o. Per cortesia, vorrei che tu mi calcolassi come cambia la probabilità che sia stato scelto il sacchetto A o il sacchetto B, sapendo che la sequenza finora estratta è: 2

Gemini si mette immediatamente in moto spiegandoci che, prima di iniziare a giocare, il due sacchetti sono caratterizzati da una **probabilità a priori** identica, 50% e 50%. Ma, sapendo che il punteggio ottenuto dal lancio è 2, Gemini fa dei calcoli utilizzando il concetto di **probabilità condizionata**, e giunge alla stima del fatto che la **probabilità a posteriori** che si tratti del sacchetto B è salita adesso al 75%. Possiamo divertirci a “dare in pasto” gli esiti alla AI, e di volta in volta le probabilità si modificano, aumentando o diminuendo, sino alla quindicesima volta quando l’esito 1 blocca il gioco e svela la verità: si trattava del sacchetto B.

Il 'random walk' della probabilità a posteriori

I numeri indicati mostrano il risultato del lancio del/i dado/i



Ma come funzionano questi calcoli? Cos'è questa probabilità condizionata? Vediamolo meglio con il nostro foglio elettronico ed il dataset her2 .

6.2 Quantificare il rischio



Viv Bewick, Liz Cheek, Jonathan Ball. Statistics review 11: Assessing risk
<https://ccforum.biomedcentral.com/articles/10.1186/cc2908>

Attività didattica 6.1 — Scheda. Probabilità nelle tavole di contingenza e misure di rischio
<https://github.com/umgstat/biotec/blob/main/schede/scheda21.pdf>

Cerchiamo di capire come possiamo applicare i concetti di **probabilità a priori** e **probabilità a posteriori** a un argomento del tutto pertinente con il nostro background biotecnologico, ossia al settore dei **test diagnostici**. Questo ci consentirà anche di riuscire a quantificare il rischio introducendo una misura molto diffusa in biostatistica, che si chiama **odds ratio**.

Non abbiamo difficoltà a credere che l'età venga riconosciuta come un fattore di rischio connesso all'insorgenza del tumore al seno; pertanto, non sorprende che nel dataset her2 una **tabella di contingenza** che esplori l'etadiagnosi e outcome ci potrà fornire alcuni indizi. Dobbiamo però, a scopo didattico, trasformare la variabile etadiagnosi da gaussiana a binomiale. Calcoliamo la mediana di etadiagnosi ed usando i filtri di Google Sheets, oppure facendoci aiutare da una Apps Script, possiamo realizzare una nuova colonna denominata eta2livelli, dichiarando rispettivamente inferiore o superiore le pazienti con età minore, ovvero maggiore o uguale, alla mediana di etadiagnosi. In questo modo, possiamo provare a realizzare una tavola di contingenza delle due nuove colonne eta2livelli ed outcome.

outcome	eta2livelli		Total
	inferiore	superiore	
decesso	505	578	1083
vivente	435	385	820
Total	940	963	1903

Nella Tabella vediamo che 1083 donne su 1903 hanno avuto un outcome sfavorevole, e pertanto si può stimare la **frequenza relativa**, cioè una stima della **probabilità a priori** della malattia, intorno al 57 per cento

$$P(\text{decesso}) = \frac{1083}{1903} = 0.569... \approx 57\%$$

■ **Vocabolario 6.1 — Prevalenza.** In un disegno trasversale (*cross-sectional*), la **prevalenza** della malattia in una sottopopolazione selezionata descritta da precisi **criteri di inclusione** è rappresentata dalla sua probabilità a priori (detta anche marginale).

Tale probabilità marginale non distingue se le donne siano più giovani (nel senso: al di sotto dell'età mediana) o più anziane. Guardiamo quindi alle colonne interne della tabella, cioè stimiamo la **probabilità condizionata**:

$$Pr(\text{decesso}|\text{inferiore}) = \frac{505}{940} = 0.537...$$

$$Pr(\text{decesso}|\text{superiore}) = \frac{578}{963} = 0.600...$$

Questi numeri appaiono differenti in senso puramente matematico: una donna “giovane” (età inferiore alla mediana) sembra avere un rischio inferiore rispetto a quello di una donna “anziana” (superiore). Pertanto ci sembra di poter capire che `età2livelli` e `outcome` non siano **eventi indipendenti**, ma eventi **associati** (in un senso statistico che preciseremo meglio più avanti). E possiamo cercare di misurare questo “grado di associazione” alla maniera degli scommettitori anglosassoni, ossia valutando il “rapporto delle quote”, ossia l’**odds ratio**:

outcome	età2livelli		Total
	inferiore	superiore	
decesso	505	578	1083
vivente	435	385	820
Total	940	963	1903

$$O.R. = \frac{505/435}{578/385} = \frac{505 \cdot 385}{578 \cdot 435} = 0.773...$$

Quando l’O.R. è “lontano” da 1 (cioè vicino a 0 oppure molto grande, diciamo 10), allora righe e colonne sono “lontane” dalla proporzionalità, e quindi un evento fornisce “una certa quantità di informazione” sull’altro evento (ad esempio essere inferiore / superiore ci informa sulla risposta vivente / decesso). Qui invece siamo piuttosto vicini ad 1, e quindi ci pare di intuire che `età2livelli` non dia molta informazione riguardo ad `outcome`.

6.2.1 Il teorema di Bayes

Nella nostra tabella di contingenza, dunque, probabilità a priori (prevalenza) e probabilità a posteriori (probabilità condizionate) sono governate dal celebre **teorema di Bayes**. Eccolo riscritto nel nostro caso:

$$P(\text{decesso}|\text{superiore}) = \frac{P(\text{superiore}|\text{decesso})}{P(\text{superiore})} \cdot P(\text{decesso})$$

Sebbene la dimostrazione matematica sia immediata, lasciamo questo compito alle colleghe di ingegneria; noi verifichiamo semplicemente la relazione con i dati del nostro esempio:

$$\begin{aligned} \frac{578}{963} &? \frac{(578/1083)}{(963/1903)} \cdot \frac{1083}{1903} \\ \frac{578}{963} &? \frac{578}{1083} \cdot \frac{1903}{963} \cdot \frac{1083}{1903} \\ \frac{578}{963} &\equiv \frac{578}{963} \end{aligned}$$

Non abbiamo tanto tempo, purtroppo, per discutere in dettaglio perché il teorema di Bayes sia diventato oggi così importante nell’inferenza statistica, e del perché le idee di Bruno de Finetti siano risultate vincenti. Ma vogliamo concludere questa sezione provando a capire bene perché $P(\text{decesso}|\text{superiore})$ e $P(\text{superiore}|\text{decesso})$ sottendono a concetti profondamente diversi. Per questo, andiamo a ricordare alcuni concetti rilevanti nella statistica medica, quando siamo chiamati a valutare la “performance di un test diagnostico”.

■ **Vocabolario 6.2 — Sensibilità e specificità.** In un disegno di ricerca trasversale (*cross-sectional*), la **sensibilità** di un test diagnostico è la probabilità di ottenere un esito positivo dal test sulle persone affette dalla malattia; al contrario, la **specificità** è la probabilità di avere un test negativo tra le persone non affette dalla malattia.

Nella nostra tabella, sensibilità e specificità sono le probabilità condizionate che leggiamo focalizzandoci sulle **colonne**:

$$\text{sensibilità} = P(\text{decesso}|\text{superiore}) = 578/963 \approx 60\%$$

$$\text{specificità} = P(\text{vivente}|\text{inferiore}) = 435/940 \approx 46\%$$

outcome	eta2livelli	
	inferiore	superiore
decesso		578
vivente	435	
Total	940	963

Queste due “metriche” sono in un certo senso il Sacro Graal dei biotecnologi, i quali sono alla ricerca di creare test diagnostici sempre più accurati (anche se purtroppo potremmo facilmente mostrare che c’è una naturale competizione tra la sensibilità e la specificità, a parità di prevalenza della patologia: all’aumentare della prima corrisponde una diminuzione della seconda, e viceversa). Viceversa, nella pratica clinica, nella real world evidence, i medici e gli epidemiologi non focalizzano la loro attenzione sulle colonne della tavola di contingenza, ma sulle **righe**:

outcome	eta2livelli		Total
	inferiore	superiore	
decesso		578	1083
vivente	435		820

■ **Vocabolario 6.3 — Valori predittivi.** In un disegno trasversale (*cross-sectional*), il **valore predittivo positivo** (PPV) è la probabilità che una persona abbia la malattia quando il test è positivo, mentre il **valore predittivo negativo** (NPV) è la probabilità che una persona non abbia la malattia quando il test è negativo.

$$\text{valore predittivo positivo} = P(\text{superiore}|\text{decesso}) = 578/1083 \approx 54\%$$

$$\text{specificità} = P(\text{inferiore}|\text{vivente}) = 435/820 \approx 53\%$$

Per approfondire tutti questi concetti, vi lascio questa referenza:



Viv Bewick, Liz Cheek and Jonathan Ball. Statistics review 13: Receiver operating characteristic curves

<https://ccforum.biomedcentral.com/articles/10.1186/cc3000>

Dal particolare all'universale

7	Oggi parliamo con Ilenia Aversa	63
8	Generalizzare un esperimento	69
8.1	Dal campione alla popolazione	69
8.2	L'errore standard della media	71
8.3	Guai a confondere la variabilità con l'affidabilità	74
9	Che cos'è un test statistico	77
9.1	il signor Student ed il suo T-Test	77
9.2	La signora che gustava il tè, ed i guai che ne seguirono	84



7. Oggi parliamo con Ilenia Aversa

Massimo: Buongiorno e ben ritrovati, care ragazze e cari ragazzi. Oggi abbiamo in aula con noi la dottoressa Ilenia Aversa, ricercatrice e coautrice di un recente studio pubblicato sul *Journal of Translational Medicine*. Diamo il nostro benvenuto ad Ilenia, ringraziandola di aver accettato il nostro invito.

Ilenia: Grazie mille, è un vero piacere essere qui con voi.

Massimo: Partiamo dall'inizio: di cosa vi siete occupati in questo lavoro di ricerca https://bit.ly/ilenia_aversa che vediamo proiettato sullo schermo? Vedo dei nomi di alcuni miei cari amici docenti e di miei ex dottorande e dottorandi.

Ilenia: Sì, esatto, il nostro studio si è concentrato sulla risposta del sistema immunitario al SARS-CoV-2, in particolare sulle cellule T. Abbiamo analizzato il cosiddetto *repertorio dei recettori T*, cioè l'insieme dei recettori che permettono alle cellule T di riconoscere il virus. In pratica, abbiamo confrontato pazienti infettati dal virus che erano vaccinati con altri non vaccinati, per capire se e come cambia la qualità della risposta immunitaria.

Massimo: Riesci a spendere qualche parola per illustrare meglio a chi come me è un profano che cosa sia il repertorio TCR β ?

Ilenia: Ho preparato per voi una presentazione, <https://github.com/umgstat/biotec/tree/main/ilenia>. Ci conviene partire dal protagonista assoluto: il linfocita T. I linfociti T sono cellule fondamentali del nostro sistema immunitario, responsabili di riconoscere in modo mirato e specifico i frammenti di agenti patogeni (come virus o batteri) o cellule tumorali. Per riconoscere i patogeni essi utilizzano un recettore specializzato posizionato sulla loro membrana, chiamato TCR (T Cell Receptor). Usualmente, il TCR è formato da due catene proteiche distinte: la catena alfa (α) e la catena beta (β) e se ingrandiamo la struttura del TCR, notiamo una zona cruciale situata all'estremità esterna: la cosiddetta regione CDR3 (*Complementarity-Determining Region 3*). La regione CDR3 è il vero e proprio "sito di legame" con l'antigene. È la porzione del recettore che entra in contatto diretto con il bersaglio ed è, di conseguenza, la parte più variabile dell'intera molecola. E poiché la catena β gioca un ruolo predominante nel definire la specificità di questo legame, studiare l'insieme di tutte le catene β diverse presenti nell'organismo significa studiare il Repertorio TCR β .

Massimo: Perché, in generale, è importante studiare questi aspetti immunitari?

Ilenia: Perché a livello immunitario le cellule T giocano un ruolo fondamentale, soprattutto contro le varianti. Mentre gli anticorpi possono perdere efficacia quando il virus muta, le cellule T tendono a riconoscere ancora il virus. Tuttavia, non tutte le risposte T sono uguali: alcune sono più efficaci di altre. Capire queste differenze ci aiuta in linea di principio a migliorare i vaccini e a prevedere la gravità della malattia.

Massimo: E quali sono stati i risultati più importanti che avete ottenuto?

Ilenia: Direi tre risultati chiave. Primo: la quantità complessiva della risposta T era simile tra vaccinati e non vaccinati. Secondo, e più importante: la differenza non riguarda la quantità, ma la qualità della risposta. I vaccinati tendevano a riconoscere regioni della proteina Spike diverse rispetto ai non vaccinati. Terzo: abbiamo identificato una regione specifica, chiamata S673–699, più frequentemente riconosciuta nei non vaccinati, che potrebbe avere caratteristiche meno favorevoli per una risposta immunitaria efficace.

Massimo: Questo cosa significa, in termini più semplici?

Ilenia: Significa che il vaccino non necessariamente fa rispondere “di più” il sistema immunitario, ma lo indirizza meglio: è come se allenasse il sistema immunitario a colpire i bersagli più utili, evitando quelli potenzialmente problematici.

Massimo: Adesso entriamo un po’ nel “dietro le quinte”: come avete realizzato concretamente questo studio? Te lo chiedo perché in questo nostro corso vogliamo anche entrare nei dettagli della metodologia della ricerca.

Ilenia: Abbiamo prelevato cellule del sangue dai pazienti e isolato i linfociti. Poi abbiamo sequenziato i recettori T per identificare i diversi clonotipi presenti. In parallelo, abbiamo stimolato le cellule in laboratorio con peptidi della proteina Spike per far espandere le cellule T specifiche. Infine, abbiamo utilizzato strumenti bioinformatici per collegare i recettori T ai frammenti della proteina virale che riconoscono.

Massimo: Quindi siete riusciti a capire cosa riconoscono queste cellule?

Ilenia: Esatto, anche se in modo indiretto. Abbiamo confrontato i nostri dati con database pubblici e utilizzato algoritmi che raggruppano recettori simili, permettendoci di inferire le specificità antigeniche. È un processo complesso, perché il sistema immunitario è estremamente variabile.

Massimo: Ilenia, però, c’è un dettaglio che balza immediatamente all’occhio: il vostro lavoro coinvolge molte figure diverse, tra clinici, biologi e bioinformatici. Qual è secondo te il prerequisito fondamentale per riuscire a fare un buon paper in un contesto così interdisciplinare?

Ilenia: Credo che la cosa più importante sia saper dialogare tra specialisti di settori diversi. In un lavoro come il nostro non è necessario che tutti siano esperti di tutto, ma è fondamentale che ci sia un linguaggio comune. Bisogna riuscire a scambiarsi informazioni in modo chiaro e a capirsi davvero, anche tra discipline diverse.

Massimo: Adesso vorrei addentrarmi nei dettagli della ricerca dal punto di vista di biostatistico: sappiamo che il primo passo in una ricerca, di solito, è quelli di sintetizzare e descrivere i dati osservati, usando le tipiche misure di centralità e di dispersione. Vedo che invece voi avete avuto la necessità di stabilire la *diversità* dei repertori delle TCR, utilizzando degli indici statistici che non sono, per così dire, “famosi”.

Ilenia: Proprio così: ci siamo affidati ad un pacchetto specifico del linguaggio R. Anche se, dovendo dire la verità, per chi come noi provenga dalle lauree nei settori delle scienze della vita, e non della matematica o dell'ingegneria, quando ci si imbatte in formule come l'indice di Simpson:

$$\lambda = \sum_{i=1}^R p_i^2$$

o l'indice di Gini-Simpson $1 - \lambda$, si ha la sensazione che siano formule “calate dall'alto”, certamente di non immediata comprensione. E poi ci siamo resi conto che ve ne sono molte altre di formule come questa, ed eravamo anche in dubbio su quali fossero più appropriate da utilizzare in un caso come il nostro.


Massimo: Lo capisco benissimo, e se mi permetti ti chiederei qualche minuto di pazienza perché vorrei spiegare questa formuletta, ragionando con le nostre biotecnologhe e i nostri biotecnologi.



7.0.1 Indici di dissimilarità



Consideriamo un ambiente ecologico in cui ci sia poca **ricchezza** di specie (solamente 2 specie: gli arancioni A ed i bianchi B), ma che ci sia una situazione di **bilanciamento**, ossia: la probabilità di estrarre a caso una pallina A oppure una pallina B “si assomiglino” (nel nostro disegno a sinistra, $p(A) = 5/9$ e $p(B) = 4/9$). L'esperimento è il seguente: estraiamo a caso una pallina, annotiamo il risultato, la reimpussoliamo nel sacchetto ed estraiamo a caso una nuova pallina; qual è la probabilità che essa sia del medesimo colore della precedente?



Un *grafo ad albero* è lo strumento giusto per rispondere a questa domanda; se $25/81$ è la probabilità di estrarre due arancioni, mentre $16/81$ la probabilità di estrarre due bianche, la somma $41/81 \approx 51\%$ è la risposta che cercavamo, quindi:

$$\lambda = p_A^2 + p_B^2 \approx 0.51$$

Passiamo ora ad una situazione di poca ricchezza e forte **dominanza** (2 specie: 8 arancioni A ed 1 bianco B). Siccome ora $p(A) = 8/9$ e $p(B) = 1/9$, avremo un aumento di λ :

$$\lambda = p_A^2 + p_B^2 = 64/81 + 1/81 \approx 0.80$$

Ora invece cambiamo la situazione, molto estrema: aumentiamo la ricchezza, con 9 possibili specie (elevata **biodiversità**, o in termini economici, non un duopolio od un quasi monopolio, ma un mercato perfetto) e ciascuna con la più bassa probabilità possibile, $p = 1/9$. Vediamo λ :

$$\begin{aligned} \lambda &= p_1^2 + p_2^2 + \dots + p_8^2 + p_9^2 = \sum_{i=1}^9 p_i^2 = \\ &= (1/9)^2 + (1/9)^2 + \dots + (1/9)^2 + (1/9)^2 = 9/81 = 1/9 \approx 0.11 \end{aligned}$$


Ecco dunque spiegato come, con un ragionamento piuttosto semplice di natura probabilistica, possiamo creare un indice $1 - \lambda$ (detto appunto di Gini - Simpson) che misuri la diversità dei repertori TCR.



Massimo: Senti, Ilenia, adesso mi tocca fare la parte del biostatistico “cattivo”: durante la lezione di ieri, in particolare nella sezione 4.2, mettevamo in luce che nella concezione frequentista (von Mises) della probabilità ci si illude di poter eseguire esperimenti con un numero elevatissimo di dati, la cosiddetta “dimensione campionaria” dovrebbe essere molto elevata. Nel vostro studio invece – e direi come quasi sempre succede in questo ed altri tipi di studi – osservate un campione di soggetti decisamente esiguo (e Bruno de Finetti sorriderebbe soddisfatto). Ti chiedo se non rappresenti questo un limite nella generalizzabilità dei vostri risultati? In fin dei conti, spessissimo ci arrivano le risposte dei reviewers che ci chiedono dettagli sul calcolo del *sample size*, vero?

Ilenia: Sì, è proprio vero: il numero di pazienti era limitato, si trattava evidentemente di uno studio pilota, esplorativo, perché eravamo appena usciti da una situazione di lock down e quindi i risultati avrebbero dovuto essere confermati su campioni più grandi. Inoltre abbiamo analizzato solo la catena beta del recettore T, mentre sappiamo che anche la catena alfa contribuisce alla specificità della risposta. Dobbiamo però d’altro canto aggiungere che tutte le nostre analisi *in silico* sono ben consolidate in letteratura, ed usualmente garantiscono un buon margine di affidabilità.

Massimo: Grazie davvero, Ilenia. Adesso vorrei aggiungere due cose; la prima è un complimento, per la vostra “Figura 3b”, che vediamo qui di seguito a sinistra. Stiamo vedendo ben rappresentati con colori diversi e con forme diverse, pallini e quadretti, i dati grezzi; inoltre riusciamo chiaramente a cogliere un’indicazione di centralità con quelle due linee orizzontali nere, oltre alla variabilità dei dati ed il loro range, nonché la dimensione campionaria dei due gruppi ($n = 6$ non vaccinati NV, $n = 8$ vaccinati V). Tutte queste informazioni invece non si capirebbero se aveste scelto di utilizzare il famigerato **dynamite plot**, che vediamo qui a destra, vero?



Ilenia: Effettivamente, in ambito biotecnologico e biologico quel tipo di grafico, simile al candelotto di dinamite, è realmente molto diffuso, soprattutto se dobbiamo presentare al lettore esperimenti con misure ripetute. Usualmente, l'altezza dei rettangoli indica la **media** dei valori che osserviamo in triplicato, mentre le sbarrette di incertezza raffigurano una quantità che si chiama **errore standard**. Non sapevo però che si chiamasse “dynamite plot”.

Massimo: Ho imparato questo nome per la prima volta leggendo il poster di Tatsuki Koyama, <https://github.com/umgstat/biotec/blob/main/libreria/Koyama2011.pdf>, e devo dire che quel poster mette in luce tutta la pochezza di quel tipo di rappresentazione (che infatti, non era stata originariamente implementata nel linguaggio R, ma è stata poi aggiunta da qualche nostalgico in qualche pacchetto aggiuntivo). Ma adesso, Ilenia, facciamo esplodere il candelotto! Guarda per cortesia cosa scrivono questi autori nella legenda della loro figura, e poi ti lascio la parola affinché tu mi dica cosa ne pensi. Essi affermano che se hanno eseguito l'esperimento in triplicato, allora le barre d'errore indicano la deviazione standard σ dei dati, mentre se hanno eseguito l'esperimento in quadruplicato, allora le barre d'errore indicano l'**errore standard della media** dei dati, un oggetto di cui ancora non abbiamo ancora discusso, che che appuntiamo sulla lavagna:

$$SEM = \frac{\sigma}{\sqrt{n}}$$




Figure 3
Slit2 mediates chemokinetic and chemotactic behaviour on endothelial cells while serum exclusively mediates chemotaxis. **A** shows the migration of control *lacZ* siRNA and *robo4* siRNA transfected endothelial cells to AP and AP-Slit2N (25 ng/ml) fusion proteins in a Boyden chamber assay. The data here is consolidated from three independent experiments with each experiment performed with samples in triplicate. **B** shows the AP activity in lysates prepared from untransfected (UT), AP and AP-Slit2N treated control and *robo4* siRNA transfected endothelial cells. **C** shows migration assay for control *lacZ* and *robo4* siRNA transfected cells to Serum or AP-Slit2N in either upper (U), lower (L) or both chambers as indicated. Error bars in **A** ($n = 3$), and **B** ($n = 3$) represent SD while in **C** represent SEM ($n = 4$). **D** shows pulldown analysis of Cdc42-GTP levels in AP and AP-Slit2N (25 ng/ml) treated endothelial cell lysates for 5 and 15 minute respectively. + indicate addition of the reagent on the left, pd: pulldown, total: total Cdc42 protein in lysates.

Ilenia: Ecco, devo dire che onestamente rimango perplessa e non saprei giustificare questa scelta, riguardo a questa arbitrarietà nel significato delle barre d'errore.

Massimo: Grazie Ilenia, la tua perplessità è condivisa. Adesso potremmo approfittare per fare una pausa ed andare a berci un caffè, ma poi al rientro in aula riprenderemo questo discorso e vedremo che questa formuletta innocua che lasciamo scritta sulla lavagna in realtà è una miccia detonante potentissima, e se non la sappiamo usare bene possiamo creare dei danni enormi. Ilenia, grazie ancora di avere accettato questo invito.

Ilenia: Grazie a voi ed un in bocca al lupo sincero per i vostri impegni imminenti con le lauree magistrali e per il proseguimento delle vostre carriere lavorative e di studio.

$$\frac{\sigma}{\sqrt{n}}$$

8. Generalizzare un esperimento

In statistica, l'obiettivo è trarre conclusioni su una popolazione a partire da un campione. Questo processo, detto inferenza, richiede che il campione sia rappresentativo, idealmente ottenuto tramite campionamento casuale, per evitare distorsioni. Una distinzione cruciale riguarda due grandezze spesso confuse: la deviazione standard misura la variabilità dei dati osservati nel campione, mentre l'errore standard misura l'incertezza associata alla stima della media campionaria come approssimazione della media della popolazione. Confondere queste due quantità significa confondere la dispersione dei dati con l'affidabilità dell'inferenza.

8.1 Dal campione alla popolazione



Elise Whitley, Jonathan Ball. Statistics review 2: Samples and populations
<https://ccforum.biomedcentral.com/articles/10.1186/cc1473>

In medical (and other) research there is generally some population that is ultimately of interest to the investigator (...). It is seldom possible to obtain information from every individual in the population, however, and attention is more commonly restricted to a sample drawn from it. The question of how best to obtain such a sample is a subject worthy of discussion in its own right and is not covered here. Nevertheless, it is essential that any sample is as representative as possible of the population from which it is drawn, and the best means of obtaining such a sample is generally through random sampling.


La citazione sopra riportata, di Elise Whitley e Jonathan Ball, introduce chiaramente l'argomento: nel nostro laboratorio raccogliamo dati da un **campione** di pazienti, di animali di laboratorio, di linee cellulari; e ci è richiesto di analizzarli al fine di fornire alcune conclusioni generali, possibilmente valide per l'intera **popolazione** a cui quel campione appartiene. Le parole di Richard Mould [16] descrivono ancora meglio la situazione:

In statistical parlance the term population refers to the group of objects, events, results of procedures or observations (rather than the geographical connotation of population relating only to persons in a country or state etc) which is so large a group that usually it cannot be given exact numerical values for statistics such as the population mean μ or the population standard deviation σ . These statistics therefore can only be estimated.

To obtain for example, an estimate of the population mean μ of a certain characteristic x of the population, *sampling* must first take place because all the values of x for the entire population cannot be measured. Only a small part of the population can be surveyed and that part is called a *sample*.

There are various methods of sampling, including *random sampling*, which for clinical trials is discussed in a later chapter as simple randomisation, stratified randomisation and balanced randomisation.


Il campionamento casuale è una sorta di “assicurazione sulla vita” contro il problema del **sampling bias** (distorsione di campionamento): noi dovremo essere sempre consapevoli, come mostrato nella prossima Figura 8.1 da Stefano Panzeri [4], che i nostri dati potrebbero essere influenzati da un tipo di “distorsione” non casuale e, nel tipico contesto di ricerca della biostatistica, quando i dati sono già stati raccolti non possiamo né individuarla né correggerla. Tanto per fare un esempio stupido, stimare l’indice di massa corporea della popolazione italiana andando a raccogliere dati alle 19.00 del venerdì fuori dalla palestra più chic della città non è affatto una grande idea, vero?



Stefano Panzeri, Cesare Magri and Ludovico Carraro. Sampling bias.
http://www.scholarpedia.org/article/Sampling_bias

Dopo aver identificato la popolazione obiettivo e dopo aver raccolto i dati dal campione, diciamo che possiamo muoverci lungo due diverse prospettive: l’**approccio bayesiano** e l’**approccio frequentista**. Entrambe le prospettive si sono consolidate nel corso dei decenni su solide fondamenta matematiche, come ricordavamo nella sezione 4.2 dedicata a Bruno de Finetti ed a Richard von Mises. Nel corso di questi seminari non avremo tempo da dedicare alla prima, ma solamente alla seconda.

8.2 L'errore standard della media



Alice: io ho 100 dischetti, con le facce colorate alternativamente di bianco e di nero, li uso per giocare ad Othello.

Bob: io ne ho 10000 di dischetti come i suoi!

Bene, abbiamo quindi questi due amichetti, ed abbiamo già intuito che Bob, il maschietto, è il solito gradasso “BMK”, mentre la bimbetta Alice è la solita leziosa e diligente bimbetta onesta. Sentiamo cos’altro hanno da dirci.

Alice: Se lancio in aria i miei 100 dischetti, quanti cadranno mostrando la faccia bianca?

Eh, beh, banale: cinquanta, circa. Lo possiamo facilmente simulare con il linguaggio R, in <https://rdr.io/snippets/>. Si tratta di simulare a caso, “random”, r , una variabile aleatoria binomiale, `binom`, dunque: `rbinom`.

codice 8.1 — Alice: lancio di 100 dischetti per 1 volta.

```
rbinom( n = 100, size = 1, prob = 0.5 )
```

■

Otteniamo come risposta una lunga sequenza di $n = 100$ risultati, zeri ed uni (che con la fantasia immaginiamo bianchi e neri). Per contarli, facciamo così:

codice 8.2 — Alice: lancio di 100 dischetti per 1 volta.

```
cento = rbinom( n = 100, size = 1, prob = 0.5 )  
table(cento)
```

■

Bob: Se lancio in aria i miei 10000 dischetti, quanti cadranno mostrando la faccia bianca?

Ovviamente, Bob non ha diecimila dischetti! Lui fa finta, prende una moneta qualsiasi e la lancia tante volte. Di sicuro non avrà voglia di lanciarla diecimila volte, imbrogliando risponderà circa 5000. Ma noi possiamo farlo agevolmente, scambiando nel linguaggio R i ruoli tra `n` e `size`:

codice 8.3 — Bob: lancio di 1 moneta per 10000 volte.

```
rbinom( n = 1, size = 10000, prob = 0.5 )
```

■

e quello che otteniamo è un numero che assomiglia a 5000, come ci immaginavamo. Adesso, attenzione a queste altre due domande:



Alice: Una volta ho lanciato i miei 100 dischetti, li ho contati e ce n'erano più di 60 bianchi. Non mi credete?

Bob: Una volta ho lanciato i miei 10000 dischetti, li ho contati e ce n'erano più di 6000 bianchi. Non mi credete?

Vi sembrano sostanzialmente la stessa cosa di prima, no? Ebbene, fra cinque minuti sorprendentemente cambieremo idea e vedremo che Alice è una bambina onesta, e Bob un bugiardone. E la cosa difficile da capire sarà il perché di tutto ciò. Procediamo in questo modo, con Alice; invece di lanciare 1 moneta per cento volte

```
rbinom( n = 1, size = 100, prob = 0.5 )
```

lanceremo contemporaneamente centomila monete, ciascuna per cento volte:

```
rbinom( n = 100000, size = 100, prob = 0.5 )
```



e disegneremo un'istogramma della situazione finale.

codice 8.4 — Alice: lancio di 100 dischetti per 100000 volte.

```
alice = rbinom( n = 100000, size = 100, prob = 0.5 )
hist(alice)
```

■

e, come vediamo, Alice non ci ha detto bugie, perchè qualche volta abbiamo ottenuto 60 successi, ed anche più. Viceversa, questo Bob è proprio un bugiardone, perchè l'istogramma, grossomodo, si attesta su un range che va da 4800 a 5200 dischetti bianchi; mai e poi mai 6000 successi.



codice 8.5 — Bob: lancio di 10000 dischetti per 100000 volte.

```
bob = rbinom( n = 10000, size = 10000, prob = 0.5 )
hist(bob)
```



Ecco! Adesso arriva il difficile: si tratta di provare a capire perché succeda questa cosa strana, che 5 minuti fa non avremmo immaginato. Proviamo a modificare di poco il codice di R, calcolando la media e la deviazione standard di quei due istogrammi.

codice 8.6 — spiegazione.

```
alice = rbinom( n = 10000, size = 100, prob = 0.5 )
mean(alice)
sd(alice)
```

```
bob = rbinom( n = 10000, size = 10000, prob = 0.5 )
mean(bob)
sd(bob)
```



giocatore	N	media	σ	$\sqrt{N}$	$\frac{\sigma}{\sqrt{N}}$
Alice	100	50	5	10	0.5
Bob	10000	5000	50	100	0.5

Tabella 8.1: Una tabella particolarmente utile, come vedremo anche nel prossimo Capitolo.

Allora, ci siamo, seguiamo questa tabella. Se passiamo da Alice a Bob, vediamo che come si “muove” N , si “muove” anche la media, **due zeri**, da 100 a 10000 e da 50 a 5000. Ma colpo di scena la deviazione standard non si muove di due, ma solamente di **uno zero**, come se fosse invece a muoversi la $\sqrt{N}$, da 10 a 100, uno zero. Questa è la prima scoperta, che spiega il perché in cinque minuti siamo passati da un tranquillo dubbio ad una inspiegabile perplessità: la curva a campana dell’istogramma di Bob è come se fosse più stretta di quella di Alice (ed è proprio così, perché in un esperimento se aumentiamo la dimensione del campione ci aspettiamo di avere maggiore precisione, minore incertezza).

Ma adesso arriva la cosa veramente difficile da capire: se calcoliamo il rapporto tra la deviazione standard σ e la radice quadrata della dimensione del campione, $\sqrt{N}$, otteniamo un rapporto costante, 0.5, che non cambia al variare di N . In altri termini, se ad Alice e Bob si aggiungessero altri bimbletti con un qualsiasi numero di dischetti e ripetessimo queste simulazioni, tutte le colonne di sinistra cambierebbero, ma quella di destra no, rimarrebbe ferma a 0.5. Ed è particolarmente importante avere sottomano qualcosa che “non si muova” se vogliamo passare dal particolare all’universale, dal nostro campione alla popolazione (proprio perché se cambiamo campione, auspichiamo di giungere sempre alla medesima conclusione riguardo all’informazione che volevamo stimare sulla popolazione a noi ignota).


Che si tratti di qualcosa difficile da capire lo intuimmo dal fatto né Euclide né Pitagora ce ne avevano mai parlato, ma che abbiamo dovuto attendere la metà del 1700, con Abraham de Moivre e la sua “curva degli errori” e con Jakob Bernoulli e il suo teorema denominato **Legge debole dei grandi numeri** per avere chiarezza sul fenomeno.

8.3 Guai a confondere la variabilità con l'affidabilità

Allora, riassumiamo. Quando vi verrà richiesto di presentare i vostri dati, vi ricorderete che:

- la **deviazione standard**, σ , DEV.ST(), ci aiuta a misurare quanta eterogeneità, quanta variabilità hanno i dati grezzi, rispetto al loro “baricentro”, i.e. la media. Infatti, la deviazione standard è un indice di **dispersione** adatto ad un contesto descrittivo dei dati (ma non potete illudervi che ripetendo in altre condizioni l'esperimento, con una altra numerosità campionaria, otterrete la medesima variabilità;
- l'**errore standard**, $\sigma/\sqrt{n}$, ci aiuta a comunicare il grado di **affidabilità** dell'informazione a cui è associato, ossia, alla media del campione, al “baricentro” dei dati. In ambito biotecnologico, comunicheremo l'errore standard per precisare quanta incertezza, quanta tolleranza dobbiamo sopportare rispetto ad una “media vera” della popolazione che non conosciamo.

Che ci sia però ancor oggi tanta confusione sul tema, è innegabile. Ho conservato lo *screenshot* (non vi racconto bugie, potete controllare voi stessi <https://jasp-stats.org/previous-versions/>) delle prime versioni di JASP, e potete vedere anche voi che l'errore standard della media veniva presentato come un oggetto descrittivo, al pari dei quartili e della deviazione standard, e non come un oggetto inferenziale di natura completamente diversa.



Ma il professor Martin Bland, un “gigante” della statistica medica,[13], ci spiega perfettamente perchè questo in effetti succeda spesso:

There is often confusion between the terms standard error and standard deviation. This is understandable, as the standard error is a standard deviation (of the sampling distribution) and the terms are often interchanged in this context. The convention is this: we use the term standard error when we measure the precision of estimates, and the term standard deviation when we are concerned with the variability of samples, populations or distributions.

Qui abbiamo tre articoli illuminanti, in tal senso: il primo, di Richard Wainer, intitolato *The most dangerous equation* [9]; il secondo, di Yu-Kang Tu and Mark Gilthorpe, intitolato *The most dangerous hospital or the most dangerous equation?* [8]. L'ultimo, ahinoi, riguarda proprio l'Università italiana ed il Ministero.

 Richard Wainer. The most dangerous equation
https://www.researchgate.net/publication/255612702_The_Most_Dangerous_Equation

 Yu-Kang Tu and Mark Gilthorpe. The most dangerous hospital or the most dangerous equation?
<https://bmchealthservres.biomedcentral.com/articles/10.1186/1472-6963-7-185>



Giuseppe De Nicolao. L'audace standardizzazione CRUI dei voti VQR: se la conosci, la eviti
<https://www.roars.it/laudace-standardizzazione-cruidei-voti-vqr-se-la-conosci-la-eviti/>

Ve li riassumo in breve. Dunque, nel Medioevo inglese, durante la cosiddetta *Trial of the Pyx*, si verificava la qualità delle monete in circolazione confrontandone il peso con uno standard di riferimento. Era noto che esistesse variabilità nel processo di conio, ma si assumeva erroneamente che tale variabilità crescesse proporzionalmente al numero di monete esaminate. In realtà, come abbiamo imparato oggi, la variabilità totale cresce con la radice quadrata del numero di osservazioni. Questo errore portò a fissare tolleranze troppo ampie, rendendo possibile, pur nel rispetto formale dei limiti complessivi, la presenza sistematica di monete sovrappeso. Tali monete potevano essere selezionate, rifiute e riconiate al peso corretto, generando una eccedenza di metallo prezioso. Sebbene non sia possibile una quantificazione precisa, è plausibile che, nel corso dei secoli, questo meccanismo abbia prodotto guadagni indebiti dell'ordine di grandezza di tonnellate di oro.

Un altro noto esempio riguarda l'analisi dei tassi di incidenza del tumore ai reni in alcune contee degli Stati Uniti. Osservando i dati, si nota che sia le contee con i tassi più bassi sia quelle con i tassi più alti tendono a essere piccole e rurali. Una lettura superficiale porterebbe a formulare spiegazioni causali opposte: vita sana nelle contee con pochi casi, condizioni sfavorevoli nelle contee con molti casi. In realtà, entrambe le osservazioni derivano dalla stessa causa statistica: le contee con popolazione ridotta producono stime molto variabili. Anche un singolo caso può far oscillare drasticamente il tasso. Le contee più grandi, invece, mostrano valori molto più stabili e concentrati. L'apparente paradosso si risolve dunque riconoscendo il ruolo della dimensione del campione.

Ancora. Negli Stati Uniti, durante gli anni Novanta, si era diffusa l'idea che scuole più piccole producessero risultati migliori. A sostegno di questa tesi si osservava che tra le scuole con le migliori prestazioni vi era una sovrarappresentazione di istituti di piccole dimensioni. Tuttavia, un'analisi più completa mostra che anche tra le scuole con i risultati peggiori le scuole piccole sono sovrarappresentate. Questo è esattamente ciò che ci si aspetta quando la variabilità è maggiore: le osservazioni si distribuiscono più frequentemente agli estremi, sia in positivo sia in negativo. In particolare, la Bill and Melinda Gates Foundation ha investito circa 1,7 miliardi di dollari in programmi volti alla promozione delle scuole di piccole dimensioni. Sebbene tale cifra non possa essere interpretata interamente come una "perdita", essa rappresenta l'ordine di grandezza delle risorse allocate sulla base di un'interpretazione fuorviante dei dati, senza considerare che la media complessiva delle prestazioni non mostrava una reale dipendenza dalla dimensione della scuola.

Anche le classifiche che individuano le città più sicure o più pericolose possono risultare fortemente fuorvianti. Spesso, tra le città agli estremi di tali classifiche compaiono centri di piccole dimensioni. Anche in questo caso, la spiegazione è puramente statistica: nelle città con pochi abitanti, il numero di incidenti o eventi rilevanti è ridotto, e quindi le fluttuazioni casuali incidono maggiormente sui tassi osservati. Una piccola variazione nel numero di incidenti può modificare drasticamente la posizione in classifica. Le grandi città, invece, avendo un numero molto maggiore di osservazioni, presentano valori più stabili e meno soggetti a variazioni estreme.

Un esempio analogo riguarda la valutazione delle prestazioni ospedaliere nel sistema sanitario inglese (NHS), dove si utilizzano indicatori come il tasso di mortalità standardizzato (HSMR) per classificare gli ospedali. Alcuni report hanno identificato ospedali "più pericolosi" o "più sicuri" sulla base di questi indicatori; ovviamente, un'analisi più attenta mostra che tali classifiche sono fortemente influenzate dalla dimensione degli ospedali. In accordo con l'equazione di de Moivre, la variabilità dei tassi osservati è molto maggiore nelle strutture piccole, che quindi compaiono più frequentemente sia tra le migliori sia tra le peggiori. Gli ospedali grandi, al contrario, presentano tassi molto più stabili e difficilmente raggiungono valori estremi. Di conseguenza, la posizione in una classifica può riflettere in larga misura fluttuazioni casuali piuttosto che differenze reali nella qualità delle cure. Questo suggerisce che l'uso di classifiche semplici può essere fuorviante e che

metodi più appropriati, come i funnel plot, sono necessari per confronti più affidabili tra strutture di dimensioni diverse.

Infine, un amaro esempio tratto dal contesto italiano riguarda le valutazioni della qualità della ricerca universitaria (VQR) e, in particolare, i tentativi di confrontare dipartimenti appartenenti a settori scientifici diversi mediante procedure di standardizzazione. In alcuni casi, l'adozione di indicatori costruiti senza un'adeguata modellizzazione della variabilità ha prodotto risultati paradossali, come il ribaltamento delle graduatorie tra dipartimenti che, in termini assoluti, presentavano prestazioni chiaramente differenti. Il problema nasce dal fatto che le distribuzioni dei punteggi variano significativamente tra settori, sia in termini di media sia di dispersione, e che procedure di normalizzazione inadeguate possono amplificare tali differenze invece di correggerle. In analogia con l'effetto descritto dall'equazione di de Moivre, gruppi di dimensioni diverse e con variabilità differenti possono apparire artificialmente migliori o peggiori quando si utilizzano indicatori non correttamente calibrati. Ne consegue che classifiche e confronti basati su tali misure possono riflettere non tanto differenze reali di qualità, quanto piuttosto artefatti statistici legati alla scala dei dati e alla loro distribuzione.

E per concludere, se volete divertirvi alle spalle dei giornalisti che non hanno studiato la statistica, vi lascio questo ricordino qui.



Tommaso Cerno. In Friuli c'è il paese d'Italia dove si legge di più.

https://www.repubblica.it/cronaca/2015/07/06/news/nel_paese_d_italia_dove_si_legge_di_piu_-118429682/



9. Che cos'è un test statistico

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

9.1 il signor Student ed il suo T-Test



Student. The probable error of a mean.

http://seismo.berkeley.edu/~kirchner/eps_120/Odds_n_ends/Students_original_paper.pdf

Nel 1908 comparve su una rivista allora emergente e molto influente, chiamata *Biometrika*, <https://en.wikipedia.org/wiki/Biometrika>, un lavoro fondamentale [6] firmato da un autore anonimo con lo pseudonimo di *Student*. Per decenni un alone di mistero circondò l'identità dell'autore, che si rivelò poi essere il matematico e chimico William Gosset, responsabile del reparto sperimentale del birrificio Guinness di Dublino (per ulteriori affascinanti dettagli si veda: https://en.wikipedia.org/wiki/William_Sealy_Gosset). Si tratta realmente di *paper* innovativo, pubblicato in una rivista innovativa per il tempo, ed ancor oggi valido come esempio comunicativo: lo sottolinea giustamente il professor Sandy Zabell [11], facendoci apprezzare il modo in cui William Gosset costruisce il suo discorso di ricerca: il problema nasce dalla pratica sperimentale, e non da un formalismo astratto. L'articolo di Gosset/Student offre un insieme di caratteristiche esemplari: si apre con un problema concreto e motivato, evitando definizioni astratte e ponendo invece una domanda reale (che cosa è lecito concludere a partire da un numero limitato di osservazioni)? A partire da qui, Gosset sviluppa l'argomentazione con una progressione narrativa estremamente chiara, introducendo dapprima il contesto pratico, discutendo poi i limiti dei metodi esistenti e mettendo infine a fuoco la difficoltà dei piccoli campioni, per arrivare solo successivamente alla formulazione teorica del risultato. E durante tutto il percorso, il testo mantiene una notevole

chiarezza epistemologica, distinguendo con precisione tra ciò che è noto, ciò che viene stimato e ciò che rimane incerto. Allo stesso tempo, pur introducendo strumenti matematici non banali, l'articolo conserva sempre un equilibrio tra intuizione e tecnica, senza mai perdere il contatto con il significato sperimentale delle quantità in gioco. Infine, l'uso di esempi concreti, inclusi semplici esperimenti empirici con materiali fisici per simulare il campionamento casuale, contribuisce a rendere il discorso vivido e accessibile. In dettaglio, il lavoro di Student / Gossett chiarisce due punti di fondamentale importanza matematica:

1. in un campione casuale estratto da una distribuzione gaussiana, la stima della media campionaria m non fornisce alcuna informazione sulla stima della deviazione standard campionaria s , e viceversa;
2. la variabile aleatoria $t = \frac{m - \mu}{s/\sqrt{n}}$ possiede una funzione di densità esplicita, che non è gaussiana, ma può essere calcolata numericamente (ma la formula è molto complicata, roba da veri matematici).

Per capire meglio questi due punti, soprattutto il secondo, procediamo passo per passo con una scheda di lavoro:

Attività didattica 9.1 — Scheda. Il test t di Student

<https://github.com/umgstat/biotec/blob/main/schede/scheda35.pdf> ■

La scheda, in breve, ci chiede di concentrarsi sulla variabile `difference` contenuta nel dataset `gossett.ods`, dopo averlo importato all'interno di un nuovo foglio Google Sheets. A questo punto, possiamo iniziare a sintetizzare l'informazione contenuta nei dati: la *media* della variabile *difference*, la *deviazione standard*, e l'*errore standard della media*. Ma spieghiamo bene di cosa stiamo parlando, leggiamo qui.

To test whether it is advantage to kiln-dry barley seed before sowing, seven varieties of barley were sown (both kiln-dried and not kiln-dried) in 1899 and four in 1900; the results are given in the table (9.1), expressed in Lbs. head corn per acre.

Sono queste le parole originali riportate nelle pagine finali del paper, con le quali William Gosset illustra il proprio metodo fornendo l'esempio concreto che consiste nello stabilire se un trattamento *ante litteram* di "biotecnologia agraria" sia utile, oppure no, per aumentare la produzione di birra, vale a dire essiccare i semi in un forno dedicato prima di seminarli. Il dataset `gossett.ods` riporta proprio i dati originali pubblicati, che vediamo qui di seguito:

La scheda chiede innanzitutto di concentrarci sulla variabile `difference` e calcolarne la media, la deviazione standard e l'errore standard della media. Riprendiamo quello schema di poco fa, la cosiddetta "tabella utile" 8.1, e compiliamola nel nostro caso attuale:

Come vedete, abbiamo aggiunto una colonna misteriosa in più, proprio perché è William Gosset a suggerirci di andare a calcolare la quantità:

$$t = \frac{m - \mu}{s/\sqrt{n}}$$

$$t = \frac{m - 0}{s/\sqrt{n}} = \frac{33.73}{19.95} = 1.69$$

Allora, cerchiamo di seguire il modo di ragionare tipico di un test statistico.

Not Kiln-Dried	Kiln-Dried	Difference
1903	2009	+106
1935	1915	-20
1910	2011	+101
2496	2463	-33
2108	2180	+72
1961	1925	-36
2060	2122	+62
1444	1482	+38
1612	1542	-70
1316	1443	+127
1511	1535	+24


Tabella 9.1: Il dataset originale di Student

variabile	N	m	s	$\sqrt{N}$	$\frac{\sigma}{\sqrt{N}}$	t
difference	11	33.73	66.17	3.32	19.95	?

1. Si parte sempre da un'ipotesi “pessimista”, “parsimoniosa”, “garantista”: il trattamento di essiccazione non serve a nulla, quindi mi aspetto che, mediamente, le differenze di trattamento siano nulle. A priori, Gossett si aspetta che la media di **difference** sarà circa uguale a $\mu = 0$.
2. Dopo l'esperimento, Gossett rileva che la media di **difference** è $m = 33.73$. Se Gossett fosse stato un ingegnere delle telecomunicazioni, avrebbe pensato a questa quantità come l'**ampiezza del segnale**, [12].
3. Trattandosi di un valore medio, possiamo anche quantificare il **rumore** medio che perturba questo segnale, ed esso è proprio quel 19.95 che abbiamo imparato a conoscere nella sezione precedente.
4. Calcoliamo ora il **rapporto segnale/rumore**, nella speranza che questo rapporto sia il più alto possibile, perché vorrebbe dire che il rumore è piccolo in confronto all'ampiezza del segnale. Otteniamo allora questo valore, $t = 1.69$
5. Conclusione: ... ?

Per trarre una conclusione, si tratta di decidere se questo rapporto segnale rumore $t = 1.69$ sia sufficientemente grande per lasciarci “detectare” il segnale e non farci sopraffare dal rumore. Vorremmo ripetere il ragionamento che abbiamo fatto poco fa con Alice e Bob ed osservare gli istogrammi dei loro esperimenti ripetuti milioni di volte. Ma purtroppo nessuno, e figurarsi William Gossett, può permettersi questo lusso; dunque, dobbiamo cercare una soluzione teorica.

Prima della scoperta di Gossett, tutti noi **sbagliando** (e sottolineo, sbagliando) avremmo immaginato che bastava considerare la variabile aleatoria normale, la distribuzione gaussiana, la cui espressione era conosciuta ormai da un secolo (e noi abbiamo imparato ieri come fare, nella sezione 4.5, usando la funzione INV.NORM.ST() per disegnare la gaussiana, e DISTRIB.NORM.ST() per calcolarne l'area). Ma Gossett ci dimostra nel suo paper, e qui sopra vediamo il suo disegno originale, che




non dobbiamo considerare la variabile aleatoria gaussiana (linea nera continua) ma una nuova distribuzione, che da quel giorno chiamiamo **t di Student**, che vediamo tratteggiata, la cui forma varia in funzione della numerosità N del campione (e che se N diventa molto grande, si avvicina alla gaussiana, nel senso matematico del “limite per N che tende all'infinito”).

Dunque, per giungere ad una Conclusione, per decidere quanto sia alto il rapporto segnale rumore $t = 1.69$, riformuliamo la domanda: quanto è probabile che il rumore non sovrasti il segnale, impedendomi di distinguerlo? Se noi, **sbagliando** (e sottolineo, sbagliando) calcolassimo l'area azzurra supponendo che la linea nera fosse la gaussiana, ovvero se usassimo `DISTRIB.NORM.ST()`, l'area risulterebbe uguale a circa 0.91, ossia avremmo un grado di fiducia del 91 per cento di riuscire a detectare il segnale; ovvero un 9 per cento di probabilità di non riuscirci. La conclusione sarebbe dunque:

5. Conclusione (**sbagliata**): c'è un 9 per cento di probabilità che la media di difference sia nulla, sia zero. E che quindi per aumentare la produzione di birra spendere soldi per comperare il forno essicatore sia inutile.

Ma qui arriva, appunto, la zampata geniale di Gossett, che sulla base della propria esperienza si è fatto un'idea precisa su queste faccende: egli ritiene che questo 9 per cento di probabilità sia troppo ottimistico, e che in realtà, nel *real world* come si dice oggi, la probabilità sia ben maggiore.



Student / Gossett invece ci fornisce la **risposta esatta**, invitandoci a calcolare la probabilità mediante questo simpatico calcolo:

$$P(-1.69 \leq T \leq 1.69) = \frac{63}{256\sqrt{10}} \int_{-1.69}^{1.69} \left(1 + \frac{x^2}{10}\right)^{-\frac{11}{2}} dx = \dots?$$

roba da far tremare i polsi a mezzo mondo: fortunatamente, questo nostro corso si intitola Biostatistica senza paura, e dunque ci rilassiamo consci del fatto che tutti i software riescono a fare questo calcolo, e vi svelano che l'area azzurra, ossia $P(-1.69 \leq T \leq 1.69)$ vale 0.878, ossia circa l'88 per cento.

Ora, viene da chiedersi perché abbia fatto la sua apparizione anche il numero -1.69 , se il consuntivo che abbiamo calcolato era $t = 1.69$? Proviamo a rispondere in questo modo: perché la scelta di calcolare la differenza tra Not Kiln-Dried e Kiln-Dried è del tutto arbitraria; Student avrebbe potuto calcolare la differenza tra Kiln-Dried e Not Kiln-Dried e la media risultante sarebbe stata $m = -33.73$ e quindi $t = -1.69$, appunto. Ecco perché in gergo in questo caso si parla di **test a due code**: perché la regione azzurrina si lascia, a destra ed a sinistra, due regioni, due code della distribuzione, appunto, bianche.

Tiriamo le fila del ragionamento, allora: la probabilità che il rumore sovrasti il segnale, ossia che $t = 1.69$ non sia alto, quindi che la media $m = 33.73$ non sia diversa da zero in senso statistico, quindi che essiccare i semi sia solamente un'inutile seccatura (ah ah ah), è del 12 per cento. Allora, sì che possiamo concludere il ragionamento:

5. Conclusione: sussiste **il 12 per cento di probabilità che non vi sia differenza**, in senso statistico, tra la resa media dei semi Not Kiln-Dried ed i semi Kiln-Dried.

9.1.1 Come eseguire il t test con il foglio elettronico

D'accordo, ma come abbiamo fatto a trovare questo valore di probabilità, questo **p - value** con Google Sheets? Effettivamente, la formula da utilizzare è decisamente criptica, misteriosa:

`=T.TEST(A2:A12;B2:B12;2;1)`

Ci chiede infatti la formula di prendere in considerazione la colonna dei dati Not Kiln-Dried, cioè l'intervallo **A2:A12**, e di considerare **in maniera appaiata** (si dice spesso "*paired data*") l'intervallo dei dati Kiln-Dried, **B2:B12**. Ecco però che, per funzionare, la funzione t test necessita di due ulteriori parametri, e il tempo a nostra disposizione non ci consente di spiegare per filo e per segno che cosa significhi effettuare un test ad una coda, oppure un test a due code; e cosa significhino i termini omoschedastico ed eteroschedastico. Quindi io vi suggerisco di ringraziare Google Sheets e salutarlo: sicuramente si tratta è un software adattissimo a raccogliere i dati, ma le analisi inferenziali fatte con R sono senza dubbio molto più complete ed adeguate. E sfruttando l'intelligenza artificiale anche i principianti non fanno fatica con la sintassi.

=T.TEST(A2:A12;B2:B12;2;1)					
A	B	C	D	E	F
nkd	kd	difference			
1903	2009	106		media	33,73
1935	1915	-20		deviazione st.	66,17
1910	2011	101		radice di N	3,32
2496	2463	-33		errore standard	19,95
2108	2180	72		t	1,69
1961	1925	-36		p value	12,2%
2060	2122	62			
1444	1482	38			
1612	1542	-70			
1316	1443	127			
1511	1535	24			

9.1.2 Come eseguire il t test con R

AI Utente

Gemini, per cortesia, sono un principiante del linguaggio R. Mi aiuti ad estrarre i dati necessari per ripetere l'analisi eseguita da Student nel suo famoso articolo comparso su Biometrika? Ti incollo qui di seguito in formato testo i dati grezzi originali:

```
nkd kd difference 1903 2009 106 1935 1915 -20 1910 2011 101 2496 2463 -33 2108
2180 72 1961 1925 -36 2060 2122 62 1444 1482 38 1612 1542 -70 1316 1443 127 1511
1535 24
```

Gemini ci risponde invitandoci a considerare il seguente codice. Se cerchiamo di interpretarne il senso, vediamo che la tabella di dati viene trasformata in due **vettori**, per mezzo della funzione `c()` che si chiamano `nkd` e `kd`. A questo punto avremmo già tutto pronto in mano, ma Gemini vuole

strafare e ci vuole insegnare come si costruisce un **data frame**, vuole controllare che la differenza che abbiamo calcolato noi non sia errata, e finalmente poi con la funzione `t.test()` ci esegue il calcolo:

codice 9.1 — il t test. Copiamo ed incolliamo in <https://rdr.io/snippets/> :

```
# Creazione dei vettori con i dati grezzi
nkd <- c(1903, 1935, 1910, 2496, 2108, 1961, 2060, 1444, 1612, 1316, 1511)
kd <- c(2009, 1915, 2011, 2463, 2180, 1925, 2122, 1482, 1542, 1443, 1535)

# Unione nel data frame originale di Student
df_student <- data.frame(nkd, kd)

# Calcolo della differenza (per verifica)
df_student$difference <- df_student$kd - df_student$nkd

# Visualizza i dati
print(df_student)

# Esecuzione del t-test accoppiato
risultato <- t.test(df_student$kd, df_student$nkd, paired = TRUE)

# Mostra i risultati
print(risultato)
```

Se schiacciamo ora il pulsante verde, Run, otteniamo questo:

Run (Cmd-Enter)

Any scripts or data that you put into this service are public.

	nkd	kd	difference
1	1903	2009	106
2	1935	1915	-20
3	1910	2011	101
4	2496	2463	-33
5	2108	2180	72
6	1961	1925	-36
7	2060	2122	62
8	1444	1482	38
9	1612	1542	-70
10	1316	1443	127
11	1511	1535	24

Paired t-test

data: df_student\$kd and df_student\$nkd
 t = 1.6985, df = 10, p-value = 0.1218
 alternative hypothesis: true difference in means is not equal to 0
 95 percent confidence interval:
 -10.72710 78.18164
 sample estimates:
 mean of the differences
 33.72727

Partiamo dal basso, cerchiamo di capire bene l'output. Innanzitutto, ma lo sapevamo già, otteniamo la media delle differenze tra Not Kiln-Dried e Kiln-Dried.

```
sample estimates:
mean of the differences
33.72727
```

Poi, torniamo un po' più in alto e leggiamo:

Paired t-test

```
data: df_student$kd and df_student$nk
t = 1.6905, df = 10, p-value = 0.1218
```

Quel numero $t = 1.69$ che noi abbiamo amichevolmente chiamato rapporto segnale rumore, ma che in una lingua italiana degna di questo nome si chiamerebbe **consuntivo**, di solito sui libri viene chiamato, in maniera erranea, **statistica test**. Il che sembra sia una specie di gioco di parole ideato per confondere gli studenti alle prime armi. In realtà si tratta di un errore di traduzione, da attribuire alla solita poca propensione degli italiani a studiare le lingue straniere. Infatti, nel vocabolario inglese, esistono due parole diverse:


1. Statistics
2. statistic

La prima, *Statistics*, è una parola **singolare** (non plurale, attenzione, la s finale inganna) la quale, al pari di Mathematics, Physics, eccetera, indica la scienza che si studia a scuola e all'università, ossia "la" statistica, come la matematica, la fisica, eccetera. La seconda parola, *statistic*, è un'altra parola singolare che significa qualcosa come "riassunto", "consuntivo", "risultanza". E infatti, come "cow boy" non significa "la vacca ragazzo", ma "il ragazzo della vacca", anche la parola "test statistic" non significa "test statistico" oppure "statistica test" ma, appunto, il consuntivo del test, il risultato del test. Gli spagnoli, per esempio, sono più fortunelli, perché distinguono "la Estadística" da "el estadístico"; i francesi invece viaggiano nelle nebbie come noi, "la Statistique" e "la statistique". Disastro!

Abbiamo poi un'altra informazione:

, df = 10,

e qui df sta per *degrees of freedom*, **gradi di libertà**. Il termine proviene dalla fisica, dalla meccanica dei corpi rigidi, ma in termini moderni potremmo interpretarlo come il numero di **informazioni libere**, e mi spiego subito con questo disegno:



Supponiamo di dover fare il t test come cento anni fa, a mano, alla lavagna; e supponiamo che io ricopi i dati di difference e mi metta a calcolare, a mano, la media $m = 33.72727$. Supponiamo ora che esco dall'aula per bere caffè, ritorno dentro e qualche spiritosone mi ha cancellato l'ultimo degli 11 dati che avevo trascritto, e mi lascia un bel punto di domanda: sono in grado io di ricostruire l'informazione mancante rispetto ai 10 dati che mi sono rimasti? Sì, ovviamente, ma con un po' di algebra: porta l'11 dall'altra parte, che moltiplica il 33, eccetera eccetera. Ecco perché qualche pagina fa, nella formula che faceva tremare i polsi:

$$P(-1.69 \leq T \leq 1.69) = \frac{63}{256\sqrt{10}} \int_{-1.69}^{1.69} \left(1 + \frac{x^2}{10}\right)^{-\frac{11}{2}} dx = \dots?$$

comparivano parecchie volte i numeri 10. Ci siamo, dunque: ci rimane ancora da prendere la decisione finale, in base all'ultima, importantissima, informazione:

```
, p-value = 0.1218
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-10.72710  78.18164
```

9.1.3 Prendere una decisione finale

Bene, e adesso? Cosa facciamo? Diciamo al signor Guinness che sì, in base al test statistico, siamo ragionevolmente certi che valga la pena di spendere soldi e comperare i forni per essicare i semi, perché nel lungo periodo questo risulterà conveniente facendoci aumentare la resa dei raccolti, giacché abbiamo solamente un 12 per cento di probabilità di sbagliarci?

Oppure, diciamo al signor Guinness che no, che sarebbero soldi buttati via, giacché abbiamo ben un 12 per cento di probabilità di inefficacia?

9.2 La signora che gustava il tè, ed i guai che ne seguirono

La risposta alla domanda precedente trovò chiarimento universale nel 1937, quando sir Ronald Aylmer Fisher diede alle stampe il suo libro fondamentale *The design of experiments* [1] presentando al mondo un esperimento estremamente curioso.

A Lady declares that by tasting a cup of tea made with milk she can discriminate whether the milk or the tea infusion was first added to the cup. We will consider the problem of designing an experiment by means of which this assertion can be tested. (...) Our experiment consists in mixing eight cups of tea, four in a way and four in the other, and presenting them to the subject for judgement in a random order. (...) It is open to the experimenter to be more or less exacting in respect of the smallness of the probability he would require before he would be willing to admit that his observation have demonstrated a positive result. (...) Thus, if he wishes to ignore results having probabilities *as high as 1 in 20* ...

Ecco dunque il punto delicato. Fisher non suggerisce una regola meccanica, non propone una soglia rigida valida in ogni situazione: propone piuttosto un criterio di buon senso sperimentale. L'idea è che i ricercatori debbano decidere, **prima di osservare i dati**, quanto debba essere “piccola” una probabilità per poter considerare un risultato degno di attenzione. In altre parole, il famoso **p-value**, nasce come una misura di evidenza contro l'ipotesi nulla, non come un interruttore acceso/spento, vero/falso. E questo si capisce benissimo proprio se ripercorriamo l'esperimento della signora che gustava il tè, esaminando l'output di questi comandi:

codice 9.2 — LadyTea.R. Provate ad inserire ciascuno di questi comandi in <https://rdr.io/snippets/>

```
dbinom( x = 0, size = 8, prob = 0.5)
dbinom( x = 1, size = 8, prob = 0.5)
dbinom( x = 2, size = 8, prob = 0.5)
dbinom( x = 3, size = 8, prob = 0.5)
dbinom( x = 4, size = 8, prob = 0.5)
dbinom( x = 5, size = 8, prob = 0.5)
dbinom( x = 6, size = 8, prob = 0.5)
```

```
dbinom( x = 7, size = 8, prob = 0.5)
dbinom( x = 8, size = 8, prob = 0.5)

\# la probabilita' di indovinarne fino a 6

dbinom( x = 0, size = 8, prob = 0.5) + dbinom(x = 1, size = 8, prob = 0.5)
+ dbinom( x = 2, size = 8, prob = 0.5)
+ dbinom( x = 3, size = 8, prob = 0.5)
+ dbinom( x = 4, size = 8, prob = 0.5)
+ dbinom( x = 5, size = 8, prob = 0.5)
+ dbinom( x = 6, size = 8, prob = 0.5)

pbinom( q = 6, size = 8, prob = 0.5)

\# Se la Lady ne indovina 7, qual e' la probabilita' che sia fortuna?

1 - pbinom( q = 6, size = 8, prob = 0.5)
```

Se la signora stesse davvero tirando a caso, avrebbe una probabilità del 50% di indovinare ogni tazza. Con otto tazze, il numero totale di risposte corrette segue una distribuzione binomiale con parametri $n = 8$ e $p = 0.5$. Possiamo quindi calcolare esattamente tutte le probabilità:

```
dbinom( x = 0, size = 8, prob = 0.5)
dbinom( x = 1, size = 8, prob = 0.5)
...
dbinom( x = 8, size = 8, prob = 0.5)
```

Questi numeri descrivono *quanto sia plausibile ciascun risultato sotto l'ipotesi nulla*, cioè sotto l'idea che la signora non abbia alcuna capacità reale di distinguere se il latte venga versato prima dell'acqua calda, i dopo. A questo punto, Fisher si chiede: quanto deve essere “straordinario” il risultato osservato per convincerci che la signora non sta tirando a caso? Se la signora indovina 4 tazze su 8, è esattamente quello che ci aspettiamo dal caso. Se ne indovina 5 o 6, siamo ancora in una zona tutto sommato plausibile. Possiamo per esempio calcolare la probabilità di ottenere al più 6 risposte corrette:

```
pbinom( q = 6, size = 8, prob = 0.5)
```

Ma se la signora ne indovina 7? Oppure tutte e 8? Qui la situazione cambierebbe drasticamente e convincerebbe lo sperimentatore. La probabilità di ottenere almeno 7 successi per puro caso è:

```
1 - pbinom( q = 6, size = 8, prob = 0.5)
```

Questo valore è uguale a $\frac{9}{256} \approx 0.035$, cioè circa un 3.5%. Ed è proprio su numeri di questo ordine di grandezza che Fisher ragiona quando parla di probabilità “abbastanza piccole” da meritare attenzione. Ecco dunque il punto delicato: Fisher non suggerisce una regola meccanica, non propone una soglia rigida valida in ogni situazione: propone piuttosto un criterio di buon senso sperimentale. L'idea è che il ricercatore debba decidere, prima di osservare i dati, quanto deve essere rara una configurazione di risultati per poterla considerare incompatibile con il caso.

Il famoso 5% nasce esattamente qui: non come una legge universale, ma come un ordine di grandezza ragionevole per esperimenti come questo. Nel caso della signora, un risultato come 7 o 8 risposte corrette cade proprio sotto questa soglia, ed è quindi considerato sufficientemente raro da giustificare un dubbio serio sull'ipotesi nulla. Fisher non avrebbe mai scritto: “se $p < 0.05$, allora c'è effetto”. Avrebbe piuttosto detto: “questo risultato è così improbabile, se fosse tutto dovuto al caso, da indurmi a sospettare che ci sia qualcosa di reale”.

Purtroppo, nel corso dei decenni successivi, questa idea sottile e ragionevole si è progressivamente trasformata in una procedura automatica. La soglia del 5%, che in Fisher era soltanto un esempio tratto da un esperimento concreto, è diventata una sorta di legge naturale. Così, poco alla volta, il valore p ha cambiato significato: da misura continua di evidenza — come nel caso della distribuzione binomiale della signora — a etichetta binaria di “significativo” e “non significativo”. Ed è qui che sono iniziati i guai.

Torniamo per un istante ai semi essiccati di Student. Il valore riportato è

p-value = 0.1218

che molti di noi oggi leggerebbero immediatamente come: “non significativo”. Ma cosa vuol dire davvero? Non significa, come si legge spesso, che esiste un 12% di probabilità che l'ipotesi nulla sia vera. Non significa nemmeno che abbiamo un 12% di probabilità di sbagliarci. Significa qualcosa di molto più preciso e, allo stesso tempo, molto più limitato: assumendo che non ci sia alcun effetto reale, qual è la probabilità di osservare dati almeno così estremi come quelli raccolti?

Una domanda tecnica, dunque, non una decisione pratica. Eppure, nella pratica scientifica del secondo Novecento, questa distinzione è stata spesso dimenticata. Il valore p diventa un lasciapassare per pubblicare, un criterio per finanziare progetti, talvolta persino una scorciatoia per prendere decisioni operative. Ma negli ultimi anni, questa situazione ha sollevato crescenti perplessità. Molti risultati “significativi” non risultano replicabili; piccoli cambiamenti nei dati o nelle analisi possono far saltare il risultato sotto la soglia del 5%; e si diffondono pratiche discutibili, come la selezione a posteriori delle analisi (*p-hacking*). Il dibattito ha raggiunto un punto cruciale nel 2016, quando l'American Statistical Association ha pubblicato un documento ufficiale sul valore p , mettendo in guardia contro il suo uso improprio. Il messaggio centrale è semplice, ma radicale: il valore p , da solo, non può fondare una decisione scientifica. Deve essere interpretato nel contesto dello studio, insieme alla dimensione dell'effetto, all'incertezza, alla plausibilità teorica e al disegno sperimentale. In altre parole, dopo cento anni, torniamo esattamente al punto di partenza: il giudizio scientifico non può essere automatizzato.

Progettare ciò che vogliamo scoprire

10

10	Dialogando con Flavia Biamonte e Martina Battaglia	89
10.1	Progettare correttamente un esperimento . . .	89
11	Conclusioni e ringraziamenti	93

10. Dialogando con Flavia Biamonte e Martina Battaglia

10.1 Progettare correttamente un esperimento

Massimo: Buongiorno ragazze e ragazzi. Oggi abbiamo con noi, non una, ma addirittura due ospiti. La prima, non ha bisogno di presentazioni perché è stata una vostra insegnante, la professoressa Flavia Biamonte. Accanto a lei, la dottoressa Martina Battaglia, biotecnologa e patologa. Benvenute e tante grazie.

Flavia e Martina: Grazie dell'invito, siamo molto felici di poter condividere con voi questa esperienza.



bioisa.umd BIostatistica SENZA PAURA

Hai paura della statistica? È il momento di cambiare idea 💡

Dal 4 al 7 maggio (9:00–13:00) arriva un ciclo di seminari pensato per gli studenti BiolSA per imparare davvero a leggere, analizzare e interpretare i dati sperimentali 📊

👉 Scoprirai come:

- ✓ progettare correttamente un esperimento
- ✓ analizzare dati biologici
- ✓ scegliere i metodi statistici giusti
- ✓ affrontare al meglio la tua tesi sperimentale

👤 Con il Prof. Massimo Borelli

📍 Aula TeamWork – Area Multimediale SBA

📁 Attività teorico-pratiche → porta il tuo PC o tablet

📱 Iscriviti tramite QR code in locandina

Massimo: Professoressa Flavia, voi siete attivamente impegnate nello studio delle interazioni tra le cellule tumorali ed il sistema nervoso, e riguardando la locandina che abbiamo postato su Instagram, <https://www.instagram.com/p/DXJxV9iDZKZ/>, non possiamo dimenticare che in queste nostre quattro giornate vogliamo anche dare spazio anche alle questioni metodologiche che precedono l'analisi statistica; in particolare il topic riguarda la corretta progettazione di un esperimento.

Flavia In questi anni abbiamo imparato che la collaborazione tra le varie figure professionali che sono coinvolte nel lavoro quotidiano di ricerca risulta essenziale, anche alla luce delle rapide trasformazioni tecnologiche che si susseguono nei laboratori di ricerca.

Massimo: Se solo ripenso a trent'anni fa, quando ho iniziato ad occuparmi di questi settori, le parole “biostatistica”, “bioinformatica”, “biotecnologie” erano praticamente sconosciute ai più.

Flavia Certamente, ma proprio per questo i chimici, i biologi, i medici di quegli anni hanno dovuto “rimettersi in gioco”, e tenere presente che la statistica non inizia quando apriamo il foglio Excel per raccogliere i dati, oppure scriviamo il codice di R per analizzarli: inizia molto prima.

Massimo: .. eh, come diceva sir Ronald Fisher, in una delle sue frasi più celebri: “Chiamare uno statistico dopo che l'esperimento è terminato equivale spesso a chiedergli di eseguire un'autopsia.”

Flavia Esatto: se l' esperimento è stato progettato male, la bioinformatica o la biostatistica ben poco possono fare per salvarlo.

Massimo: Martina, per favore, adesso prova a “farmi entrare” meglio nei dettagli scientifici e raccontaci anzitutto il problema biologico che avete studiato.

Martina: Ci siamo occupati di un fenomeno che osserviamo spesso nel carcinoma squamocellulare del cavo orale: la cosiddetta invasione perineurale. In pratica le cellule tumorali tendono a colonizzare e seguire il decorso dei nervi periferici. Sappiamo che questo comportamento è associato ad una prognosi peggiore, ma non comprendiamo ancora completamente quali segnali molecolari lo favoriscano.

Massimo: Quindi il tumore ed il nervo si parlano?

Martina: Esattamente. L'ipotesi è che esista una forma di comunicazione reciproca mediata da proteine secrete nell'ambiente extracellulare. Queste proteine costituiscono quello che chiamiamo *secretoma*. Per questo abbiamo deciso di studiare il secretoma di una linea tumorale denominata OT1109 e di cellule neuronali.



Massimo: Quando parli di secretoma, a che cosa dobbiamo pensare?

Martina: Ad una sorta di collezione di messaggi molecolari. Ogni cellula rilascia proteine, fattori di crescita, citochine e altre molecole. Studiando queste sostanze possiamo cercare di capire quali segnali vengano inviati alle cellule vicine.

Massimo: E come avete costruito l'esperimento?

Martina: Abbiamo utilizzato due tipi cellulari: neuroni e cellule OT1109. Ciascun tipo cellulare poteva essere coltivato da solo oppure esposto al mezzo condizionato prodotto dall'altro tipo cellulare. In questo modo ottenevamo quattro “gruppi di dati”, quattro condizioni sperimentali.

Massimo: Fermiamoci un istante. Hai detto una frase apparentemente innocua: “ottenevamo quattro condizioni sperimentali”. Io sospetto però che in questa frase sia nascosta più statistica di quanto sembri; proviamo a rappresentare il problema in una tavola di contingenza.

	Senza CM	Con CM
Neuroni	N	N + OT1109-CM
OT1109	T	T + Neuron-CM

Vediamo comparire immediatamente due fattori sperimentali:

- il tipo cellulare;
- il condizionamento.

Non stiamo quindi osservando quattro gruppi indipendenti qualsiasi. Stiamo osservando un vero e proprio **disegno fattoriale** 2×2 .

Martina: In questo aspetto, ci è stato di grande aiuto consultare la AI, poiché in effetti noi rimaniamo soprattutto concentrati sugli aspetti biologici e talvolta non riflettiamo troppo sulla struttura matematica del disegno sperimentale, sugli aspetti della randomizzazione, del controllo locale, della replicazione. Infatti, nel nostro caso avevamo previsto tre replicati biologici per ciascuna condizione.

Massimo: E qui vi faccio una domanda che ogni biostatistico ama fare su cosa significhi esattamente “tre replicati biologici”, su cosa comporti questa scelta. In dettaglio, immaginiamo invece di avere tre pozzetti provenienti dalla stessa preparazione cellulare, raccolti nello stesso giorno e dallo stesso passaggio cellulare. Potremmo considerarli tre replicati biologici?

Martina: No, in tal caso avremmo soltanto tre misure ripetute della stessa preparazione.

Massimo: Esattamente. Ecco perché l'**unità sperimentale** è un concetto così importante. Supponiamo di avere una torta, noi possiamo pesare quella stessa torta tre volte ed otteniamo tre misure. Ma abbiamo una torta sola. Oppure possiamo preparare tre torte indipendenti, otteniamo ancora tre misure, ma questa volta però possediamo tre unità sperimentali. La differenza forse sembra banale ma decide il valore della nostra dimensione campionaria, n , e modifica l'esito del test statistico.

Martina: Infatti nel nostro studio ogni replicato biologico era inoltre la media di tre replicati tecnici.

Massimo: Ecco, e questa è una scelta che in passato metodologicamente si riteneva corretta: i replicati tecnici gestiscono l'errore di misura, i replicati biologici gestiscono la variabilità biologica. Sono due cose completamente diverse, ed oggi disponiamo di tecniche statistiche appropriate per modellare questi aspetti, anche se purtroppo il nostro tempo volge alla conclusione e non riusciamo a fornire maggiori dettagli.

Martina: Eppure ancor'oggi molti ricercatori tendono ancora a confonderle. Noi, per esempio, abbiamo misurato nel secretoma circa una trentina di proteine per ciascuna analisi, e molti potrebbero essere tentati di dire: “Tre replicati per trentatré proteine: abbiamo quasi cento osservazioni per gruppo.” Ma non sarebbe corretto, perché tutte quelle proteine provengono dallo stesso campione biologico e quindi non sono indipendenti.

Massimo: Benissimo. Qui compare un termine che ogni ricercatore dovrebbe conoscere: **pseudoreplicazione**. L'errore consiste nel trattare misure ripetute come se fossero nuovi individui sperimentali. E questo porta a valori-p artificialmente piccoli. Per non parlare poi delle importanti questioni delle procedure di controllo del *False Discovery Rate*, o dei *Multiple Comparison*. Ma purtroppo, dobbiamo fermarci perché arriva il momento della verifica conclusiva e della attribuzione dei crediti formativi. Professoressa Flavia, cara Martina, grazie davvero per questa conversazione e complimenti in anticipo per le vostre future ricerche.

Flavia e Martina: Grazie a voi e un sincero augurio di buon lavoro a tutte le future biotecnologhe e a tutti i futuri biotecnologi presenti in aula.



11. Conclusioni e ringraziamenti

Cominciamo con i ringraziamenti. Senza dubbio, il nome della professoressa Donatella Malanga arriva per primo. Ed accanto al nome preciso abbiamo anche, caso piuttosto raro (non come la monetina che si appoggia sul fianco, ma insomma ..), una data precisa, ed una location precisa, su, a Trieste. La data è quella del 1 giugno 2025 e la location è il famosissimo *Bar de Kiwi's* di Palazzo Glicini. Nelle foto ci vedete brindare, con una limonata analcolica ovviamente; e se non credete che che si tratti di una limonata analcolica, potete consultare la lista delle bevande preparata in quel bar: <https://palazzoglicini.weebly.com/menu.html>. È stata proprio in quell'occasione che Donatella mi pose la domanda "... ma perché non scendi a fare un corso ai miei biotec come quello che fai ai dottorandi? Dai, pensiamoci, organizzo tutto io". Ed eccoci qua.



Un altro nome da ringraziare è quello del professore Salvatore Losacco, biologo marino ed oceanografo. Salvatore ha continuato in questi ultimi anni a riutilizzare le vecchie "macro" di MS Excel per aiutarsi a gestire il lavoro routinario (ed estenuante) di incrociare tabelle di dati destrutturati, facendosi però aiutare dall'intelligenza artificiale per ottimizzarne le performance. Qualche mese fa, mi sono seduto accanto a lui alla sua scrivania, ed ascoltando le sue parole dopo pochi minuti ho intuito che questa poteva diventare una chiave che apriva una nuova porta didattica, una svolta innovativa per accostarsi senza stress ai linguaggi di programmazione, i quali sono tanto utili quanto ostici a chi desideri applicarli agli argomenti del nostro corso. Il terzo nome da ringraziare è quello del professore Sergio Invernizzi: una delle persone (o come dicono i medici, dei Maestri) attraverso cui, in questi ultimi trentacinque anni, tramite mail, viaggi in treno, telefonate, messaggi, revisioni di pdf, scambi di codici di R, post su FaceBook, si sono sedimentate nella mia mente parecchie risposte sensate ad innumerevoli "domande difficili" alle quali non sapevo dare risposta. E poi ci sarebbe tutta una lista di nomi di persone con le quali, non appena sbarco dall'aeroplano a Sant'Eufemia, o metto piede nei corridoi di Germaneto, mi accolgono con le braccia aperte e con un sonoro "Ueeeeeee ...", ma la lista diventa di anno in anno più lunga, e quindi avrei un problema di rapida obsolescenza di questa dispensa, con la quale invece punto ad arrivare, rapidamente, ad una serena vecchiaia, sdraiato al famosissimo *Bar de Kiwi's* di Palazzo Glicini, che per voi è sempre aperto – mandatemi un messaggio quando volete un aperitivo: <https://www.instagram.com/massiminoborellino/>.

Bibliografia

Articoli

- [1] Ronald Aylmer Fisher et al. "The design of experiments." In: *The design of experiments*. 2nd Ed (1937) (citato a pagina 84).
- [2] Gregg C Fonarow et al. "An obesity paradox in acute heart failure: analysis of body mass index and inhospital mortality for 108 927 patients in the Acute Decompensated Heart Failure National Registry". In: *American heart journal* 153.1 (2007), pagine 74–81 (citato a pagina 43).
- [3] Eckhard Limpert, Werner A. Stahel e Markus Abbt. "Log-normal Distributions across the Sciences: Keys and Clues". In: *BioScience* 51.5 (2001), pagine 341–352 (citato a pagina 43).
- [4] Stefano Panzeri, Cesare Magri e Ludovico Carraro. "Sampling bias". In: *Scholarpedia* 3.9 (2008), pagina 4258 (citato a pagina 70).
- [5] Christer Sinderby et al. "An automated and standardized neural index to quantify patient-ventilator interaction". In: *Critical Care* 17.5 (2013), pagine 1–9 (citato a pagina 52).
- [6] Student. "The probable error of a mean". In: *Biometrika* (1908), pagine 1–25 (citato a pagina 77).
- [7] Nick Thieme. "R generation". In: *Significance* 15.4 (2018), pagine 14–19 (citato a pagina 12).
- [8] Yu-Kang Tu e Mark S Gilthorpe. "The most dangerous hospital or the most dangerous equation?". In: *BMC health services research* 7.1 (2007), pagina 185 (citato a pagina 74).
- [9] Howard Wainer. "The most dangerous equation". In: *American Scientist* 95.3 (2007), pagina 249 (citato a pagina 74).
- [10] Donna M Windish, Stephen J Huot e Michael L Green. "Medicine residents' understanding of the biostatistics and results in the medical literature". In: *Jama* 298.9 (2007), pagine 1010–1022 (citato a pagina 10).
- [11] Sandy L Zabell. "On student's 1908 article "the probable error of a mean"". In: *Journal of the American Statistical Association* 103.481 (2008), pagine 1–7 (citato a pagina 77).
- [12] Stephen T Ziliak e Deirdre N McCloskey. "The cult of statistical significance". In: *Ann Arbor: University of Michigan Press* 27 (2008) (citato a pagina 79).

Libri

- [13] Martin Bland. *An introduction to medical statistics*. Ed. 3. Oxford University Press, 2000 (citato alle pagine 24, 74).
- [14] Joseph K Blitzstein e Jessica Hwang. *Introduction to probability*. Chapman e Hall/CRC, 2019 (citato a pagina 35).
- [15] Michael C Joiner e Albert Van der Kogel. *Basic clinical radiobiology*. Volume 1. CRC press, 2016 (citato a pagina 44).
- [16] Richard F Mould. *Introductory medical statistics*. CRC Press, 1998 (citato a pagina 69).
- [17] Vijay K Rohatgi. *Statistical inference*. John Wiley & Sons, 1984 (citato a pagina 30).
- [18] Bernard A Rosner. *Fundamentals of biostatistics*. Duxbury Press, 1995 (citato a pagina 24).

- [19] Hadley Wickham e Garrett Grolemund. *R for data science: import, tidy, transform, visualize, and model data*. O'Reilly Media, Inc., 2016 (citato a pagina 12).

Indice analitico

- bias, 70
- Come eseguire il t test con il foglio elettronico, 81
- Come eseguire il t test con R, 81
- Dal campione alla popolazione, 69
- data quality, 25
- dataset
 - her2, 57
 - complete, 25
- descriptive statistics, 23
- deviazione standard, 74
- distribuzioni statistiche, 40
 - di Poisson, 43
 - di Weibull, 45
 - lnormale, 40
 - lognormale, 41
- Due pensieri a confronto: von Mises e de Finetti, 37
- errore standard, 74
- frequence
 - relative, 57
- Guai a confondere la variabilità con l'affidabilità, 74
- Il linguaggio R, 12
- il signor Student ed il suo T-Test, 77
- inclusion criteria, 57
- Indici di dissimilarità, 65
- L'errore standard della media, 71
- La signora che gustava il the, ed i guai che seguirono, 84
- Le variabili aleatorie discrete, 35
- measures
 - location, 23
 - variability, 23
- odds ratio, 58
- parametro, 46
- population, 69
- predictive value
 - negative, 59
 - positive, 59
- Prendere una decisione finale, 84
- prevalence, 57
- Probabilità a priori ed a posteriori, 53
- probability
 - conditional, 57
 - frequentist, 57
 - marginal, 57
- Progettare correttamente un esperimento, 89
- Quantificare il rischio, 57
- quantiles, 29
 - deciles, 29
 - percentiles, 29
 - quartiles, 29
- sample, 69
- sampling
 - random, 69
- sensibilità, 59
- Siamo pronti: la famigerata Tabella 1, 49
- Simulare numeri casuali, 38
- specificità, 59
- teorema
 - Bayes, 58
 - llegge debole dei grandi numeri, 73
- Un grafico con il nome buffo: il QQ plot, 46
- variabile aleatoria
 - Poisson, 44
- viridis, 31